



UNIVERSIDADE DE SANTIAGO DE COMPOSTELA

ESCUELA POLITÉCNICA SUPERIOR DE LUGO

Grado en Ingeniería en Geomática y Topografía

**ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE
MANGLE EN EL GOLFO DE FONSECA
APLICACIÓN A LA CLASIFICACIÓN DE IMÁGENES LANDSAT**

Alumno:

Marcos Rial Docampo

Tutores:

Eduardo José Corbelle Rico

Rafael Enrique Corrales Andino

Lugo - 2015

Análisis de separabilidad espectral de especies de mangle en el Golfo de Fonseca

Aplicación a la clasificación de imágenes Landsat

Marcos Rial Docampo

10 de julio de 2015



Esta obra está sujeta a la licencia Reconocimiento-CompartirIgual 3.0 España de Creative Commons. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-sa/3.0/es/> o envíe una carta a Creative Commons, 444 Castro Street, Suite 900, Mountain View, California, 94041, USA.

Aquí se colocan los agradecimientos.

Resumen/Abstract

Resumen

Abstract

Índice general

Resumen	V
Índice de Figuras	X
Índice de Tablas	XI
Lista de Acrónimos	XV
1. Introducción	1
1.1. Marco Global	1
1.2. Objetivos	4
1.2.1. Objetivo general	4
1.2.2. Objetivos específicos	5
1.3. Zona de estudio	6
1.4. Bases teóricas de teledetección	8
1.4.1. Fundamentos	8
1.4.2. Espectro electro-magnético	9
1.4.3. Términos y unidades	11
1.4.4. Firma espectral	13
1.4.5. Sensores	15
1.4.6. Resoluciones	18
1.4.7. Correcciones	21
1.4.8. Clasificación	24
1.4.9. Índices de vegetación	29

2. Material y métodos	33
2.1. Estudio radiométrico	33
2.1.1. Datos	33
2.2. Software	35
2.3. Técnicas de análisis espectral	38
2.3.1. Índice de acuerdo espectral	38
2.3.2. Continuum removal	39
2.3.3. Clasificación angular	42
2.4. Imágenes de satélite	43
2.4.1. Landsat 8	43
2.4.2. Obtención de las imágenes	44
2.4.3. Tratamientos previos	47
2.5. Clasificación de imágenes	52
2.6. Índices de vegetación	57
3. Resultados	59
3.1. Análisis de separabilidad	59
3.1.1. Análisis visual	59
3.1.2. Índice de Acuerdo Espectral	60
3.1.3. Continuum Removal	63
3.1.4. Clasificación angular	64
3.2. Combinación de bandas	64
3.3. Comprobación	64
3.4. Clasificación de imágenes	69
3.5. Índices de vegetación	69
4. Conclusiones	71
Bibliografía	79
Anejo. Mapas	81

Índice de figuras

1.1.	Mangle en el Golfo de Fonseca	2
1.2.	Distribución mundial de manglar	3
1.3.	Estanques de cría de camarón	4
1.4.	Salineras	5
1.5.	Localización del Golfo de Fonseca	7
1.6.	Modelo de elevación del Golfo de Fonseca	7
1.7.	Elementos de teledetección	9
1.8.	Espectro electro-magnético	9
1.9.	Firma espectral ejemplo	14
1.10.	Biblioteca espectral SIGFIRM	15
1.11.	Clasificador <i>K-Nearest Neighbor</i>	27
1.12.	Clasificador de paralelepípedos	28
1.13.	Clasificador de máxima verosimilitud	29
2.1.	Mangle recolectado	34
2.2.	Obtención de firmas	34
2.3.	Función de Índice de Acuerdo Espectral	39
2.4.	Continuum Removal ejemplo	40
2.5.	Función de <i>Continuum Removal</i>	41
2.6.	Función modificada de <i>Continuum Removal</i>	42
2.7.	Función clasificación angular	43
2.8.	Imágenes Landsat	46
2.9.	Imágenes de calidad de Landsat	47
2.10.	Valores nulos	48

2.11. Mosaico de imágenes	49
2.12. Diálogo del mosaicado	50
2.13. Mosaico de imágenes en GRASS	50
2.14. Recorte de la imagen	50
2.15. Filtro de paso bajo	52
2.16. Composición en color real	53
2.17. Composición en falso color	53
2.18. Generación de firmas <i>i.cluster</i>	54
2.19. Clasificación con <i>i.maxlik</i>	54
2.20. Detalle de áreas de entrenamiento	55
2.21. Conversión vectorial a ráster	55
2.22. Función de <i>Spectral Angle Mapper</i>	56
 3.1. Firmas espectrales de las tres especies	59
3.2. Firmas espectrales cortadas	61
3.3. Firmas espectrales cortadas de las tres especies	62
3.4. Gráfica de Continuum Removal	63
3.5. Composición 654	65
3.6. Composición 562	65
3.7. Actualización de coordenadas	66
3.8. Actualización de los datos raster	66
3.9. Reescalado de valores	67
3.10. Distribución de puntos	68
3.11. Gráfico de puntos de comprobación	68
3.12. Detalle marismas en NDVI	69
3.13. Detalle de estanques en SAVI	70
 4.1. <i>Map Swipe</i> de GRASS 7	73

Índice de cuadros

1.1. Bandas espectrales utilizadas en teledetección	10
1.2. Bandas en el sensor TM	16
1.3. Bandas en el sensor ETM+	17
1.4. Bandas en el sensor OLI	17
1.5. Resoluciones de varios sensores	21
1.6. Otros tipos de índices de vegetación	31
2.1. Puntos de control	35
2.2. Características de las imágenes Landsat	46
2.3. Datos de las regiones de trabajo	51
2.4. Base de datos de áreas de entrenamiento	57
3.1. Valores medios en las bandas Landsat	60
3.2. Valores de IAE	62
3.3. Valores medios de la respuesta espectral	63
3.4. Valores de Ángulo Espectral	64
3.5. Base de datos de puntos de comprobación	67

Lista de Acrónimos

AGPL: *Affero General Public License.*

API: *Application Programming Interface.*

AVHRR: *Advanced Very High Resolution Radiometer.*

AWS: *Amazon Web Services.*

CODDEFFAGOLF: Comité para la Defensa y Desarrollo de la Flora y Fauna del Golfo de Fonseca.

CR: *Continuum Removal.*

CRAN: *The Comprehensive R Archive Network.*

DVI: *Difference Vegetation Index.*

EPSG: *European Petroleum Survey Group.*

EROS: *Earth Resources Observation and Science Center.*

ETM: *Enhanced Thematic Mapper.*

ETM+: *Enhanced Thematic Mapper Plus.*

EVI: *Enhanced Vegetation Index.*

GDAL: *Geospatial Data Abstraction Library.*

GDVI: *Green Difference Vegetation Index.*

GeoTIFF: *Geographic Tagged Image File Format.*

GNDVI: *Green Normalized Difference Vegetation Index.*

GPL: *General Public License.*

GRASS: *Geographic Resources Analysis Support System.*

HRV: *High Resolution Visible.*

IFOV: *Instantaneous Field of View.*

IAE: Índice de Acuerdo Espectral.

IRC: Infrarrojo Cercano.

- IRM: Infrarrojo Medio.
- IRT: Infrarrojo Térmico.
- ISF: Ingeniería Sin Fronteras.
- IV: Índices de Vegetación.
- JHU: *Johns Hopkins University*.
- JPL: *Jet Propulsion Laboratory*.
- K-NN: *K-Nearest Neighbor*.
- L1T: *Level 1 Terrain*.
- LPPL: *ETEX Project Public License*.
- MLC: Maximum Likelihood Classifier.
- ND: Nivel Digital.
- NDVI: *Normalized Difference Vegetation Index*.
- NIR: *Near Infrared*.
- NN: *Nearest Neighbor*.
- NV: Nivel Visual.
- OLI: *Operational Land Imager*.
- OSGeo: *Open Source Geospatial Foundation*.
- PL8SR: *Provisional Landsat 8 Surface Reflectance*.
- SAM: *Spectral Angle Mapping*.
- SAVI: *Soil Adjusted Vegetation Index*.
- SCP: *Semi-automatic Classification Plugin*.
- SIG: Sistema de Información Geográfico.
- SIGFIRM: Sistema de Gestión de Firmas Espectrales Agrícolas.
- SMAP: *Sequential Maximum A Posteriori*.
- SR: *Surface Reflectance*.
- SVN: *Apache Subversion*.
- SWIR: *Short Wave Infrared*.
- TFG: Trabajo Fin de Grado.
- TIFF: *Tagged Image File Format*.
- TIRS: *Thermal Infrared Sensor*.
- TM: *Thematic Mapper*.

TOA: *Top of Atmosphere*.

USC: Universidade de Santiago de Compostela.

USGS: *United States Geological Survey*.

UTM: *Universal Transversa de Mercator*.

WGS84: *World Geodesic System 84*.

Capítulo 1

Introducción

1.1. Marco Global

Antes de comenzar conviene diferenciar los términos mangle y manglar. Comúnmente se conoce como mangle a la especie forestal (árbol o arbusto) que crece en el ecosistema del manglar o también llamados bosques de mangle (figura 1.1). Por lo tanto, en este documento se hablará de especies de mangle y se recurrirá al manglar o bosque de mangle para determinar la zona en la que viven estas especies.

Los manglares componen en la costa de centroamérica uno de los sistemas medioambientales más extensos y complejos del mundo. Situados en la zona intermareal próxima a las desembocaduras de los ríos o esteros, están compuestos por más de 80 especies diferentes de árboles y siendo hábitat de más de 2000 especies de animales, algunas de ellas migratorias.

La importancia ecológica y comercial de este sistema propio de zonas tropicales y subtropicales, como se muestra en la figura 1.2, es notable puesto que previenen la erosión de la línea de costa y sirven como sustento económico de la población en forma de producción de la industria pesquera y aporte de madera, leño y carbón ([Lara-Domínguez et al. , 1999](#)).

Centroamérica posee muchos kilómetros de costa en relación a su área territorial, con relaciones cercanas a que por cada kilómetro de costa existen 80km^2 de continente y cerca



Figura 1.1: Aspecto del mangle en un estero del Golfo de Fonseca. Fotografía de Rafael Enrique Corrales.

del 70% de su población vive a menos de 100 km de la costa. Estos datos representan, más si cabe, la importancia de estas zonas para la población y da una idea de su valor económico.

El manglar es un ecosistema delicado y dependiente de los procesos que ocurren fuera de sus fronteras, como pueden ser cambios en las escorrentías de los ríos que afectan a estas zonas, alteraciones en la calidad del agua, provocadas por ejemplo por contaminantes arrastrados por la deriva, o porcentaje de salinidad de las aguas. Esto convierte a mareas, ríos y corrientes litorales como principales agentes alteradores del ecosistema manglar, pero también existe una componente humana importante que afecta directamente.

Los bosques de mangle de esta región están compuestos por bosque de mangle alto y bosque de mangle bajo. El bosque alto es el situado sobre la línea de costa y su altura varía entre los 5 y los 10 metros, mientras que el bosque bajo se sitúa contiguo al alto en zonas más cercanas a tierra. En el bosque de mangle alto conviven las especies *Rhizophora mangle* y *Laguncularia racemosa*. En el bosque de mangle bajo conviven mayormente las especies *Avicennia germinans* y *Conocarpus erectus*. Estas especies, excepto la última, serán descritas más adelante en el capítulo de Materiales y Métodos (2).



Figura 1.2: Distribución mundial del manglar. Fuente: Wikimedia Commons.

En cambio, el manglar es un ecosistema gravemente amenazado. Como se mencionaba, el impacto ambiental, directo e indirecto, no solo procede de la creación de infraestructuras, expansión urbana y desarrollo de industria petrolera sino también de la reconversión en zonas de cría de camarón (figura 1.3) o agricultura costera y salinas (figura 1.4) que deterioran la calidad del agua. Otras causas del deterioro a escala global de los manglares serían la escasa legislación de la propiedad de recursos naturales, los cambios de actividad de las comunidades costeras, las malas decisiones políticas, la ausencia de planes de desarrollo costero, la depreciación del valor ecológico, la explotación no sostenible o el desconocimiento de las consecuencias ([Yáñez-Arancibia & Lara-Domínguez, 1994](#)).

Una de las posibles soluciones que mitiguen estas causas es la de conocer mejor este ecosistema y su funcionamiento. Precisamente esta es una de las finalidades de este Trabajo Fin de Grado (TFG).

El empleo de sensores remotos para proyectos relacionados con el medioambiente y el entorno forestal es una realidad y se han utilizado mucho estas últimas décadas con unos buenos resultados. Como por ejemplo, [Bodart et al. \(2011\)](#) y [Cajacuri \(2011\)](#) realizan un estudio multitemporal de los cambios sufridos por las coberturas forestales, mientras que el estudio de [Chen et al. \(2013\)](#) se centra precisamente en analizar los cambios en el bosque de mangle hondureño apoyándose en imágenes Landsat. [Lee & Yeh \(2009\)](#) destacan la utilización de sensores remotos por la velocidad y precisión a la hora de recabar datos y



Figura 1.3: Estanques dedicados a la cría de camarón en el Golfo de Fonseca. Fotografía de Rafael Corrales Andino.

comparan la utilización de diferentes sensores.

1.2. Objetivos

1.2.1. Objetivo general

El objetivo general del trabajo es el de evaluar la posibilidad de emplear imágenes obtenidas con sensores remotos para diferenciar las distintas especies de mangle que se encuentran en el Golfo de Fonseca.

De todas las especies de mangle existentes en el Golfo de Fonseca se ha decidido tomar tres para este estudio por ser las más predominantes. Son las siguientes:

- Mangle Rojo. Nombre científico *Rhizophora mangle* ([Jiménez, 1985b](#)).
- Mangle Blanco. Nombre científico *Laguncularia racemosa* ([Jiménez, 1985a](#)).
- Mangle Prieto. Nombre científico *Avicennia germinans* ([Jiménez & Lugo, 1985](#)).



Figura 1.4: Extensión de terreno dedicada a la producción de sal. Fotografía Rafael Enrique Corrales.

La hipótesis desde la que se parte es que la respuesta espectral de las diferentes especies de mangle sea lo suficientemente diferente para que este objetivo se cumpla. Esto conduce a la realización de unos objetivos específicos en los que se busca concretar más en el trabajo.

1.2.2. Objetivos específicos

Los objetivos específicos serán el análisis de separabilidad espectral de las especies de mangle del Golfo de Fonseca y determinar la utilidad potencial del empleo de imágenes Landsat para diferenciar las especies analizadas.

Una vez realizado el análisis de especies se aplicarán los datos extraídos para realizar una clasificación supervisada de una imagen de la zona de estudio captada por el sensor *Operational Land Imager* (OLI) y obtenida del servicio de descargas de *United States Geological Survey* (USGS), la denominada *Earth Resources Observation and Science Center* (EROS), gracias a su herramienta Earth Explorer. De esta clasificación se sacarán distintas conclusiones y se analizará la superficie de cada especie de manglar.

Se parte de la hipótesis de que, dependiendo de los resultados del primer objetivo, sea posible aplicar la experiencia adquirida en el análisis de separabilidad para realizar una

clasificación fiable de la zona.

A esto se le añade el propósito de que, a lo largo de todas las fases del presente trabajo, se estudiará el uso de software libre y las posibilidades que este presenta de cara a futuros proyectos. Estas fases son: redacción del documento, tratamiento, análisis y presentación de los datos así como el tratamiento y procesado de las imágenes. Se presentarán las virtudes y defectos de este tipo de software y se analizarán los problemas presentados.

Este trabajo tiene como referencia el proyecto de Ingeniería Sin Fronteras (ISF) y el Comité para la Defensa y Desarrollo de la Flora y Fauna del Golfo de Fonseca (CODDEFFAGOLF) en colaboración con la Universidade de Santiago de Compostela (USC) que tiene como título: “Investigación y sensibilización sobre la problemática de la actividad acuícola insostenible y promoción de alternativas artesanales basadas en la economía social: puentes entre Golfo de Fonseca y Galicia” ([LaboraTe, 2014](#)).

1.3. Zona de estudio

El área de estudio es el entrante natural del Golfo de Fonseca (figuras [1.5](#) y [1.6](#)) que abarca la costa pacífica de El Salvador, Honduras y Nicaragua situado entre las latitudes $13,595824^{\circ}\text{N}$ – $12,757449^{\circ}\text{N}$ y las longitudes $87,994615^{\circ}\text{W}$ – $87,115709^{\circ}\text{W}$.

De toda el área forestal de Honduras, que se sitúa en torno a las 54000000000km^2 , los manglares ocupan alrededor de un $1.0\% 515781800\text{km}^2$ ([CIPF, 2014](#)). La mayor parte de este porcentaje de manglar se localiza en la costa pacífica del país, en el Golfo de Fonseca, que posee gran riqueza y diversidad de recursos naturales que están amenazados por su sobreexplotación ([Jiménez, 1994](#)). Esto hace que figure en la lista Ramsar de humedales protegidos a escala mundial ([Ramsar, 2014](#)). En total cuenta con 409 km de costa abarcando una extensión de 547km^2 .

El Golfo de Fonseca, caracterizado por tener unas aguas poco profundas, que oscilan entre los 30m y 10m de máxima y 0.5m de mínima, está formado por una serie de ecosistemas interrelacionados formados por estuarios interiores, manglares, costas continentales e

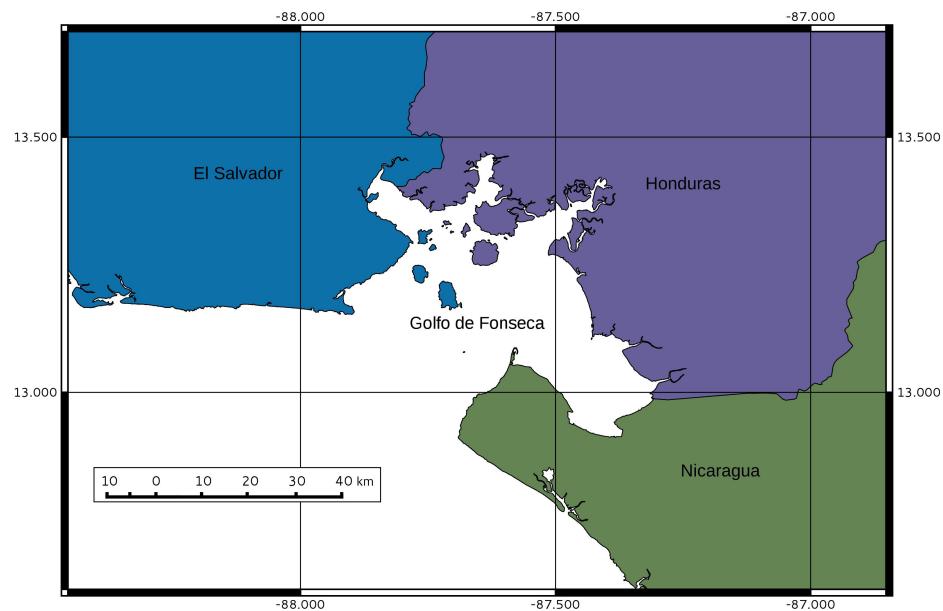


Figura 1.5: Localización del Golfo de Fonseca. Fuente: Elaboración propia. Datos: [Global Administrative Areas \(2012\)](#).

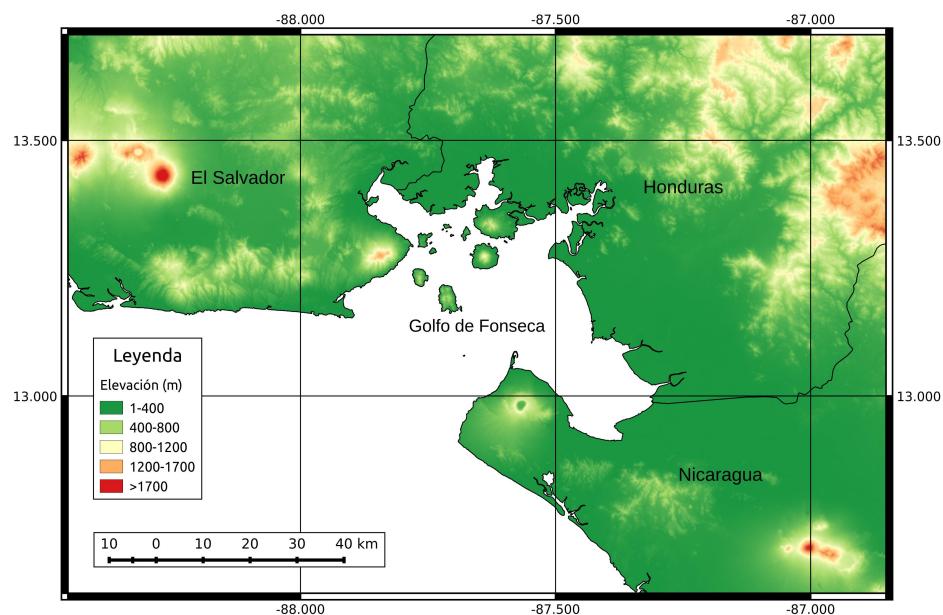


Figura 1.6: Modelo de elevación del Golfo de Fonseca. Fuente: Elaboración propia. Datos: [Jarvis et al. \(2008\)](#).

insulares. Las cuencas del Río Goascorán y el Río Negro son transfronterizas; la primera es compartida por El Salvador y Honduras y la segunda por Honduras y Nicaragua. Es pues un espacio internacional con humedales compartidos, lo que le otorga una importancia mayor a la hora de ser gestionado.

Cabe destacar que en 1998 el huracán Mitch devastó una extensa superficie del ecosistema del Golfo de Fonseca causando incontables pérdidas humanas y económicas y cubriendo de lodo las zonas de manglar llegando a provocar un ligero cambio en la línea de costa debido a las crecidas de los ríos y a las amplias mareas ([CEPAL, 1999](#)).

1.4. Bases teóricas de teledetección

1.4.1. Fundamentos

La teledetección es la técnica que nos permite obtener información de los objetos situados en la superficie de la Tierra realizando una observación remota ([Curran, 1989](#)) ([Chuvieco Salinero, 2002](#)) ([Schowengerdt, 2006](#)). Para que esta observación sea posible debe haber algún tipo de nexo entre el objeto y el sistema sensor u observador. De esta afirmación se extraen los tres elementos básicos de la teledetección: el objeto observado, el sensor y el flujo energético que los relaciona.

Hay tres formas de que un sensor pueda adquirir la información del objeto. Estas son: por reflexión, por emisión y por emisión-reflexión.

La primera forma deriva directamente de la reflexión solar (será la empleada en este TFG) como se muestra en la figura [1.7](#). El Sol (A) ilumina la superficie terrestre que refleja esa energía (C) en función del tipo de cubierta (B). El flujo reflejado es recogido por el sensor (D) que, de ser portado por un satélite, debe atravesar una capa de atmósfera que dispersa y absorbe parte de la señal. El flujo energético entre la cobertura y el sensor constituye una forma de radiación electro-magnética ([Olaya, 2010](#)).

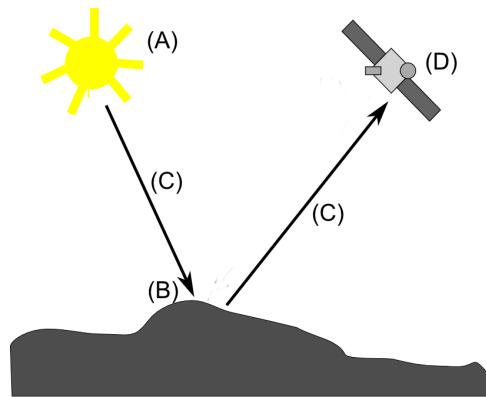


Figura 1.7: Elementos de teledetección. Fuente: [Olaya \(2010\)](#).

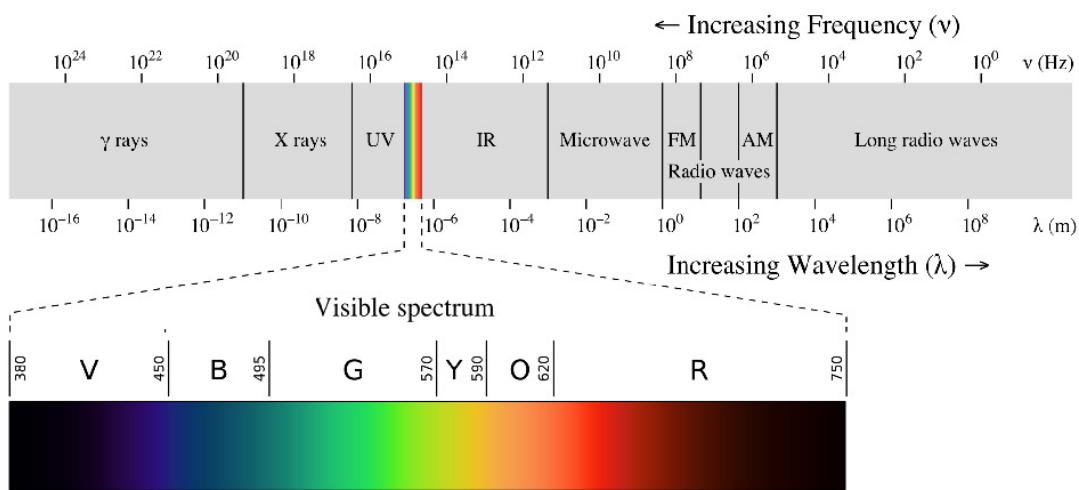


Figura 1.8: Frecuencias y longitudes de onda del espectro electro-magnético. Fuente: [Wikimedia Commons](#).

1.4.2. Espectro electro-magnético

Podemos definir cualquier tipo de energía en función de su longitud de onda, de la que se establecen una serie de bandas en donde la radiación electro-magnética manifiesta un comportamiento similar. Esta organización en bandas se denomina espectro electro-magnético (figura 1.8). Esta comprende desde longitudes de onda corta, como los rayos gamma (γ) con menos de $10^{-11}m$, a longitudes de onda mayores de un metro como las ondas de radio.

En el cuadro 1.1 se destacan la serie bandas espectrales más empleadas en teledetección, siendo su denominación y ancho de banda el generalizado.

El espectro visible es la única radiación electromagnética perceptible por la vista. Como

Cuadro 1.1: Bandas espectrales utilizadas en teledetección.

	Banda	L. de onda
Visible	Azul	$0,4 - 0,5\mu m$
	Verde	$0,5 - 0,6\mu m$
	Rojo	$0,6 - 0,7\mu m$
Infrarrojo	Cercano (IRC)	$0,7 - 1,2\mu m$
	Medio (IRM)	$1,2 - 8,0\mu m$
	Térmico (IRT)	$8,0 - 14,0\mu m$
Microondas (M)		$> 1mm$

se muestra en el cuadro 1.1 esta banda se divide en otras tres elementales: azul, verde y rojo; en razón de los colores primarios que los ojos perciben a esas longitudes de onda.

En el caso de la banda infrarroja esta también se divide en tres bandas elementales: Infrarrojo Cercano (IRC), Infrarrojo Medio (IRM) e Infrarrojo Térmico (IRT). El IRC, también denominado próximo, es de especial importancia puesto que es utilizado para detectar masas vegetales y concentraciones de humedad. En el IRM tenemos que diferenciar el *Short Wave Infrared* (SWIR) o infrarrojo de onda corta (situado entre 1.2 y $2.5\mu m$ resultando una banda indicada para estimar el contenido en humedad de la vegetación y los suelos) y el IRM propiamente dicho (situado entre 2.5 y $8\mu m$ siendo determinante para la detección de focos de alta temperatura como incendios).

El IRT es el indicado para dimensionar las emisiones de temperatura de las cubiertas sobre la superficie terrestre. Es poco utilizado para otros fines.

Las microondas tienen interés por ser un tipo de energía capaz de penetrar la cubierta nubosa pero no se tendrá en cuenta en este tipo de trabajos.

En capítulos sucesivos veremos que los valores de los intervalos de longitudes de onda de las bandas tomadas por los sensores satelitales son ligeramente diferentes a los mostrados

en este capítulo.

1.4.3. Términos y unidades

Como se indicó anteriormente, para que se pueda producir la observación remota es preciso que el sensor detecte un flujo energético proveniente de las cubiertas sobre la superficie terrestre. Este flujo energético tiene una intensidad determinada que proviene o está dirigida a una cubierta determinada con una dirección concreta. Se definen a continuación las magnitudes absolutas empleadas en teledetección.

- Energía radiante (Q). Indica el total de energía radiada en todas las direcciones. Es medida en Julios (J).
- Flujo radiante (ϕ). Es el total de energía radiada en todas las direcciones por unidad de tiempo. Es medida en vatios (W). Se compone de flujo reflejado (ϕ_r), flujo absorbido (ϕ_a) y flujo transmitido (ϕ_t).
- Emitancia radiante (M). Es el total de energía radiada en todas las direcciones por superficie y por unidad de tiempo. Es medida en vatios por metro cuadrado (Wm^{-2}).
- Irradiancia (E). Es el total de energía radiada sobre una unidad de superficie y por unidad de tiempo. Es equivalente a la emitancia, excepto a que se refiere a la energía incidente y no a la emitida. Es medida en Wm^{-2} .
- Intensidad radiante (I). Es el total de energía radiada por unidad de tiempo y por ángulo sólido (Ω). Este ángulo es tridimensional y refiere a la sección completa de la energía transmitida (es medido en estéreo-radianes). La intensidad radiante se mide en vatios por estéreo-radian (Wsr^{-1}).
- Radiancia (L). Es el total de energía radiada en una determinada dirección por unidad de superficie y por ángulo sólido de medida. Es uno de los términos más importantes en teledetección porque es la magnitud que mide el sensor. Se cuantifica en vatio por metro cuadrado y estéreo-radián ($Wm^{-2}sr^{-1}$).
- Radiancia espectral (L_λ). Indica el total de energía radiada en una determinada longitud de onda por unidad de área y por ángulo sólido de medida.

De igual forma se definen magnitudes relativas que son adimensionales:

- Emisividad (ϵ). Es la relación entre la emitancia de la superficie (M) y la emitancia de un emisor perfecto (cuerpo negro) a igual temperatura.
- Reflectividad (ρ). Es la relación entre el flujo reflejado y el incidente.
- Absortividad (α). Es la relación entre el flujo absorbido y el incidente.
- Transmisividad (τ). Relación entre el flujo transmitido y el incidente.

Debido a que la radiancia que capta un sensor depende de la que refleja la cubierta en la que incide, para detectar una cubierta por teledetección se precisa explicar como interactúa con la radiación solar incidente. El flujo incidente (ϕ_i), como ya se mencionó, se descompone en tres términos: flujo reflejado (ϕ_r), flujo absorbido (ϕ_a) y flujo transmitido (ϕ_t), es decir:

$$\phi_i = \phi_r + \phi_a + \phi_t \quad (1.1)$$

que expresado en términos relativos:

$$\frac{\phi_i}{\phi_i} = \frac{\phi_r}{\phi_i} + \frac{\phi_a}{\phi_i} + \frac{\phi_t}{\phi_i} \quad (1.2)$$

lo que es igual a la suma de la reflectividad, absorbtividad y transmisividad ha de ser igual a uno:

$$1 = \rho + \alpha + \tau \quad (1.3)$$

que variando según la longitud de onda (λ) bastaría con expresarlo de la siguiente manera:

$$1 = \rho_\lambda + \alpha_\lambda + \tau_\lambda \quad (1.4)$$

La cantidad de flujo incidente que es reflejado, transmitido y absorbido dependen directamente de las características de la cubierta que se está observando y de la longitud de onda a la que se observa. Para conocer fielmente las características de una cubierta conviene observarla a distintas longitudes de onda, lo que permitirá diferenciarla de otras cubiertas susceptibles de ser espectralmente similares.

La variación de longitud de onda, por ejemplo en el espectro visible, se detecta fácilmente pues se ve afectado en nada menos que el color en el que observamos. Un objeto será rojo,

verde o azul si refleja la energía de la banda del espectro correspondiente o si absorbe más intensamente la de las otras bandas.

El flujo de energía recibida por el sensor depende, además de la reflectividad de la cubierta, de las condiciones atmosféricas, el emplazamiento ambiental de la cubierta y la geometría de la observación. El sensor puede registrar distintos valores para el mismo tipo de cubierta dependiendo de la variación en las condiciones de observación o iluminación. Hay que tener en cuenta que una cubierta vegetal presenta distintos estados biológicos a lo largo del año, lo que añade una componente temporal a la toma de datos. En resumen, los factores que afectan a las características espectrales de una cubierta son:

- Ángulos de iluminación y observación, que varían con la latitud, fecha del año y hora de la observación y la posición del sensor.
- Modificaciones que el relieve introduce en el ángulo de iluminación, como pueden ser la orientación de las laderas de una montaña o pendientes.
- Influencia de la atmósfera, absorción por nubes y dispersión selectiva en distintas longitudes de onda.
- Variaciones medioambientales en la cubierta: asociación con otras superficies, homogeneidad que presenta o estado fenológico entre otras.
- Sustrato edafológico o litológico, especialmente influyente cuando la cubierta observada presenta una densidad media.

1.4.4. Firma espectral

La firma o signatura espectral (figuras 1.9 y 1.10), extraído del inglés *spectral signature*, es la forma de reflejarse que tiene una cubierta a lo largo de distintas longitudes de onda y se utiliza para discriminar una cubierta de otra a partir de una observación remota. Son fundamentales para reconocer cubiertas de interés o extraer parámetros o características intrínsecas a dicha cubierta. La firma espectral se puede obtener de las siguientes fuentes:

- Medidas con un radiómetro.

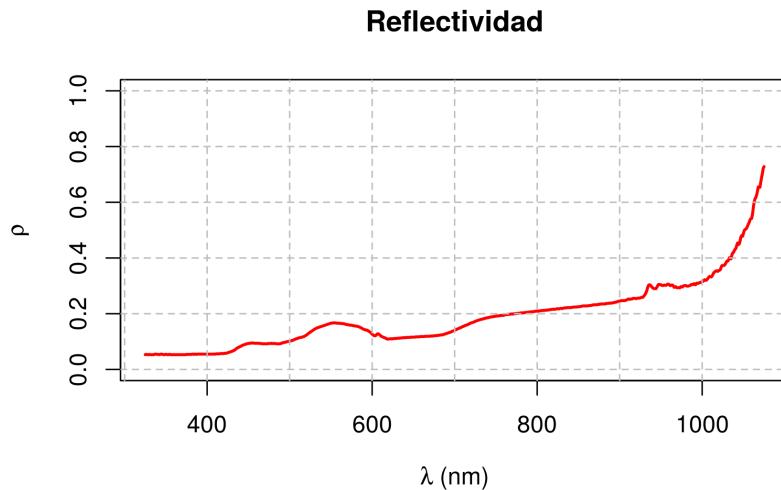


Figura 1.9: Firma espectral ejemplo de una cubierta no identificada. Fuente: Elaboración propia.

- Bibliotecas espetrales.
- Simulaciones mediante modelos físicos.
- Imagen con la debida resolución espectral.

El medio más sencillo de disponer de firmas espetrales son las bibliotecas espetrales. Las bibliotecas espetrales son colecciones de firmas espetrales, tomadas en condiciones controladas por radiómetros en laboratorio, que sirven de referencia para conocer el comportamiento de una cubierta determinada (Corrales Andino, 2010a).

Hay numerosos ejemplos de bibliotecas espetrales en Internet, como las del Sistema de Gestión de Firmas Espectrales Agrícolas (SIGFIRM) venezolano que recoge el comportamiento espectral de los cultivos en regiones agrícolas de Venezuela 1.10; o la ASTER spectral library de la NASA, que recoge datos de otras tres bibliotecas espetrales: las del *Johns Hopkins University* (JHU), *Jet Propulsion Laboratory* (JPL) y USGS registrando más de 2400 firmas de materiales como minerales, rocas, suelos y algunas cubiertas artificiales como lo son cemento, aluminio o papel.

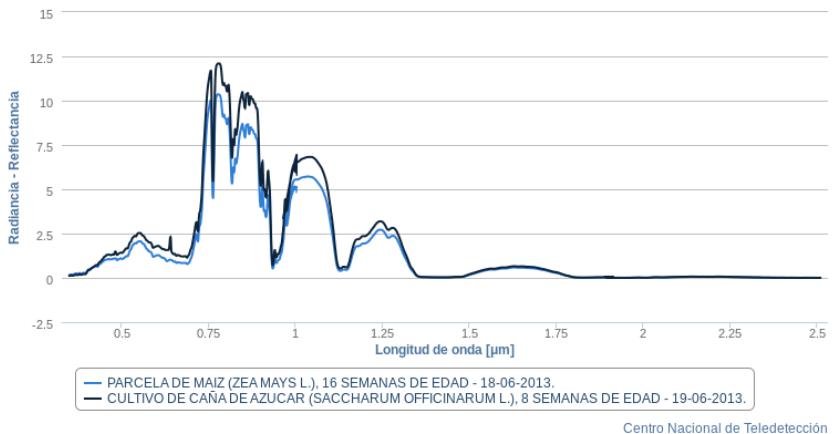


Figura 1.10: Biblioteca espectral de maíz y caña de azúcar. Fuente: SIGFIRM

1.4.5. Sensores

En el apartado de fundamentos (1.4.1) de este mismo capítulo se indicaba que el sistema sensor era una de los tres componentes principales de la teledetección.

La clasificación más común de los sensores es según la forma de recibir la energía de las cubiertas, dando lugar a:

- Pasivos, donde el sensor recibe la energía emitida por un agente exterior (e.g. el Sol).
- Activos, donde el sensor recibe un haz de energía emitido por él mismo (e.g. radares).

Sensores pasivos

En una clasificación más detallada de los sensores pasivos estos se dividen en sensores fotográficos (cámaras analógicas), óptico-electrónicos (exploradores de barrido, de empuje y cámaras de vídeo) y de antena (radiómetros de microondas), en función del procedimiento que emplean para recibir la radiación procedente de los objetos.

Lo que concierne a este TFG serán los sensores pasivos óptico-electrónicos ya que las cámaras analógicas eran más utilizadas en fotogrametría aérea y los radiómetros de microondas trabajan en frecuencias muy elevadas.

Los sensores óptico-electrónicos combinan una óptica similar a las cámaras analógicas

Cuadro 1.2: Bandas en el sensor TM del proyecto Landsat. Fuente: USGS.

Banda	Nombre	L. onda (μm)	Resolución (m)
1	B	0.45–0.52	30
2	G	0.52–0.60	30
3	R	0.63–0.69	30
4	NIR	0.76–0.90	30
5	NIR	1.55–1.75	30
6	TIR	10.40–12.50	120
7	MIR	2.08–2.35	30

con un sistema de detección electrónica permitiendo prescindir de un soporte sólido de grabación de imágenes. El sensor convierte la señal de radiancia proveniente del objeto en un valor digital. Los sensores exploradores de barrido, que son los más habituales, utilizan un espejo que oscila perpendicularmente a la dirección de la trayectoria.

Un ejemplo de sensor remoto pasivo de barrido es el *Enhanced Thematic Mapper Plus* (ETM+) montado sobre el satélite Landsat 7. Otro ejemplo de explorador de barrido son los sensores *Thematic Mapper* (TM) del Landsat 5, el OLI del Landsat 8 (de cuyas imágenes se hará uso en este TFG y se le dedicará un parágrafo) o el *Advanced Very High Resolution Radiometer* (AVHRR) del NOAA. De los tres primeros se extraen los cuadros 1.2, 1.3 y 1.4.

Otro tipo de sensor pasivo son los exploradores de empuje. En estos se elimina el espejo oscilante, en cuyo lugar se disponen una serie de detectores que cubren todo el campo de visión del sensor que exploran, en cada momento, una línea completa desplazándose esta línea simultáneamente con la plataforma. Estos exploradores permiten aumentar la resolución espacial y agilizan la detección de datos al hacer la conversión radiancia a valor digital por línea y no por píxel como los anteriores.

Ejemplos de exploradores de empuje son los sensores *High Resolution Visible* (HRV) del SPOT o los sensores portados por los satélites IKONOS o Quickbird.

Cuadro 1.3: Bandas en el sensor ETM+ del proyecto Landsat. Fuente: USGS.

Banda	Nombre	L. onda (μm)	Resolución (m)
1	B	0.45–0.52	30
2	G	0.52–0.60	30
3	R	0.63–0.69	30
4	NIR	0.77–0.90	30
5	NIR	1.55–1.75	30
6	TIR	10.40–12.50	60
7	MIR	2.08–2.35	30

Cuadro 1.4: Bandas en el sensor OLI del proyecto Landsat 8. Fuente: USGS.

Banda	Nombre	L. onda (μm)	Resolución (m)
1	Coastal	0.43–0.45	30
2	B	0.45–0.51	30
3	G	0.53–0.59	30
4	R	0.64–0.67	30
5	NIR	0.85–0.88	30
6	SWIR	1.57–1.65	30
7	SWIR	2.11–2.29	30
9	Cirrus	1.36–1.38	30

1.4.6. Resoluciones

Se define la resolución del sistema sensor en teledetección como la capacidad para discriminar información de detalle en un objeto. Otra definición utilizada es la de valor mínimo determinado para alguna de las variables que definen a una imagen digital ([Chuvieco Salinero, 2002](#)).

El concepto de información de detalle de la primera definición comprende tanto al detalle espacial que ofrece el sensor como a número y anchura de bandas espectrales, a su carencia temporal y a la capacidad para distinguir variaciones en la energía que detecta. Esto significa que el concepto de resolución se basa en el conjunto de:

1. Resolución espacial.
2. Resolución espectral.
3. Resolución radiométrica.
4. Resolución temporal.

Resolución espacial

Designa el objeto más pequeño que es posible distinguir en la imagen digital. Se mide en milímetros sobre la imagen o metros sobre el terreno y depende de la longitud focal del sensor y altura sobre la superficie. En sensores óptico-electrónicos se utiliza el *Instantaneous Field of View* (IFOV), que se define como la sección angular que observa el sensor en un momento determinado.

$$d = 2h \tan(\text{IFOV}/2) \quad (1.5)$$

donde d es la distancia sobre el terreno que abarca con ese ángulo IFOV, y h la altura del sensor sobre el terreno. Esta mínima unidad de información en la imagen es la que se denomina píxel.

La resolución espacial de un sensor, como ya se ha mencionado, depende de varios factores, como la altura orbital, la longitud focal y el número de detectores. En los sensores de

antena, la resolución espacial depende del tamaño de la antena, la altura de la plataforma y el ángulo de incidencia.

Dependiendo de la resolución espacial tenemos cuatro tipos de sensores:

1. De alta resolución. Con resoluciones próximas al metro de ancho.
2. De recursos naturales. Con resoluciones entre los 25 x 25m y 1000 x 1000m.
3. De baja resolución. Por lo general montados sobre satélites geoestacionarios y dedicados a ámbitos meteorológicos, cuentan con una resolución espacial que puede llegar a los 5 x 5km.

Resolución espectral

Designa el número y anchura de bandas espectrales que puede discriminar el sensor. Es muy importante la capacidad del sensor para registrar simultáneamente el comportamiento de un mismo objeto en varias bandas del espectro. En definitiva, un sensor tendrá mayor resolución cuanto mayor número de bandas detecte, facilitando así la caracterización espectral de las cubiertas.

Es evidente la importancia que tiene la elección del sensor en cuanto al número de bandas, ancho y longitud de las mismas dependiendo del objetivo del trabajo a realizar. Por ejemplo, para la detección de vegetación se hace más importante disponer de bandas del IRC e IRM más que del IRT, en cambio para detectar incendios sí es importante disponer de la banda del IRT.

Resolución radiométrica

Designa la sensibilidad del sensor o su capacidad para detectar las variaciones en la radiancia espectral. En los equipos digitales, como por ejemplo el sensor ETM+, la imagen es codificada en un formato binario, por lo que la resolución radiométrica se identifica con el rango posible de valores que almacena el sensor, medido como el número de bits que necesita cada valor numérico para almacenarse. El mencionado ETM+ ofrece una resolución de 8 bits, es decir, 256 niveles por píxel.

La importancia de este tipo de resolución se hace patente a la hora de interpretar las imágenes, sobre todo cuando esta interpretación es digital, ya que el ordenador aprovecha todo el rango de resolución radiométrica.

Resolución temporal

Designa la frecuencia de cobertura que proporciona el sensor, es decir, la periodicidad con la que adquiere imágenes de la misma zona de la superficie terrestre. Esto depende de las características orbitales de la plataforma (altura, velocidad e inclinación) y del diseño del sensor (del ángulo total de apertura). La resolución temporal dependerá también de las condiciones atmosféricas puesto que una amplia cobertura nubosa impedirá la observación y dilatará dicha temporalidad.

Las variaciones en la resolución temporal responden al objetivo para el que esté diseñado el sensor, pudiendo llegar a los 15 o 30 minutos de los satélites meteorológicos como Meteosat y hasta los 15 o 31 días de los satélites de recursos naturales como el Landsat o Spot.

Resolución angular

Designa la capacidad de un sensor de tomar instantáneas de una misma porción de terreno desde distintas órbitas. Esto se relaciona con la resolución temporal en que, tomando el supuesto de que en un momento dado la cobertura nubosa impide la observación, el sensor tome la imagen desde una órbita cercana en otro lapso de tiempo inclinándose para poder hacerla. Esta capacidad reduce el efecto de reflectividad bidireccional que presentan algunas cubiertas y los efectos de absorción y dispersión de la atmósfera.

En el cuadro 1.5 se comparan las diferentes resoluciones de los principales sensores para fines medioambientales que hay actualmente en órbita.

Cuadro 1.5: Resoluciones de varios sensores.

	Landsat 8 OLI	QuickBird	Spot 6	IKONOS
		HRV		
R. Espacial MS (m)	30–60	2.44–2.88	6	3.2–4
R. Espectral (nm)	450–12500	450–900	455–890	445–853
R. Radiométrica (bits)	8	11	12	11
R. Temporal (días)	16	1–3	1–3	3

1.4.7. Correcciones

Como se exponía anteriormente la imagen digital tomada por el sistema sensor se compone de una malla de píxeles que toman un valor numérico concreto obtenido a partir de la radiancia observada. Ese valor numérico que codifica cada píxel es el llamado Nivel digital (ND). La propiedad más ventajosa de esos ND es que pueden traducirse a color o niveles de gris, por ejemplo mediante el uso de un monitor, dependiendo, la intensidad, del ND. A partir del ND visualizado se pueden hacer operaciones de realce que no modificarán su valor pero sí harán que se vea con diferente intensidad. A este nuevo valor se le llamará Nivel visual (NV). El ND, en cambio, es utilizado para operaciones de interpretación digital, especialmente cuando estas se relacionan con parámetros como la reflectividad o la temperatura.

La mejor forma de ver una imagen es como si fuera un sistema de tres dimensiones, donde las dos primeras dimensiones corresponden a la posición geográfica de la imagen y la tercera corresponde al ND.

Las correcciones propiamente dichas son aquellos procesos con los que se eliminan anomalías detectadas en la imagen, tanto de localización como en la radiometría de los píxeles. La finalidad de estos procesos es la de disponer los datos de la forma más cercana a lo que sería una adquisición idónea (e.g. posición geográfica correcta). Es posible que la corrección más importante sea la geográfica, pues aporta validez cartográfica a los resultados y permite la conexión con otros datos geográficos en un Sistema de Información Geográfico (SIG).

Las principales fuentes de error que provocan la necesidad de realizar correcciones son:

- Distorsiones originadas por la plataforma. El alabeo, el cabeceo o el giro lateral son movimientos que modifican la altitud de órbita del satélite, la velocidad o la orientación, lo que se traduce en problemas en la adquisición de las imágenes. Problemas como lo son cambios en la escala de adquisición o distorsiones en la geometría.
- Distorsiones provocadas por la rotación terrestre. En algunos sensores la toma de la imagen supera los 20 segundos, tiempo en el que la Tierra se desplaza en rotación unos 6 kilómetros.
- Distorsiones provocadas por el sensor. Distorsiones debidas al tipo de sensor relacionadas con el ángulo de barrido o el campo de visión global, provocando distorsiones cuanto más alejados están los píxeles del nadir.
- Distorsiones provocadas por la atmósfera. Los elementos de la atmósfera causan una modificación en la obtención de la señal original de la superficie terrestre. El efecto más importante es la dispersión, que implica un aumento de la señal recibida por el sensor.

La última de las distorsiones, la atmosférica, resulta importante de corregir para generar índices espectrales.

Correcciones radiométricas

Las correcciones radiométricas son aquellas técnicas que modifican los ND originales con el objetivo de acercar su valor al que sería obtenido bajo condiciones ideales. Son correcciones radiométricas:

- Restauración de líneas o píxeles perdidos. La imagen presenta líneas blancas o negras píxeles de aspecto contrastado al resto. Es una corrección aproximada, puesto que no se pueden poner píxeles de valor correcto donde no hay información.
- Corrección del bandeadío de la imagen. Es especialmente perceptible en zonas de agua y problemático en los exploradores de empuje. Es un defecto periódico.

- Cálculo de reflectividades. Es una corrección muy importante para el análisis e interpretación de imágenes, pues como se decía anteriormente, es preferible trabajar con términos físicos que con ND. Particularmente es importante a la hora de comparar datos con otros obtenidos con radiómetros de campo (uno de los objetivos de este TFG).
- Cálculo de temperaturas.
- Detección de nubes.

Correcciones geométricas

Este tipo de correcciones incluyen los cambios en la posición que los píxeles ocupan en la imagen digital. Son correcciones basadas en funciones numéricas que se aplican sobre la geometría de la imagen y la modifican.

$$f(c') = f_1(c, l); f(x, y) \quad (1.6)$$

$$f(l') = f_2(c, l); f(x, y) \quad (1.7)$$

Las coordenadas columna y línea c' y l' de la imagen corregida son función de las coordenadas columna y línea de la imagen de entrada c y l o de las coordenadas del mapa al que se pretende superponer la imagen x e y . Se trata de encontrar una relación que convierta los ND de la imagen a su posición cartográfica en la proyección requerida (en este caso a la *Universal Transversa de Mercator (UTM)*). Esto permite, entre otras cosas, hacer un mosaico con más imágenes para ampliar la cobertura de la imagen.

Hay dos procedimientos de corrección geométrica que se pueden aplicar a una imagen que se enumeran a continuación:

1. Corrección a partir de modelos orbitales. Corrige los errores provocados por fuentes conocidas a partir de aplicar transformaciones inversas a las que realiza el sensor

en el momento de la adquisición de los datos. Se necesita conocer con precisión las características orbitales de la plataforma y las especificaciones del sensor. Se corrigen de esta forma los errores sistemáticos

2. Corrección a partir de puntos de control. Modela el error geométrico a partir de puntos de control repartidos a lo largo de la zona de la imagen. Estos puntos son de coordenadas conocidas y se asume que sean lo suficientemente representativos de las deformaciones de la imagen.

El primero de los procedimientos es especialmente indicado para aquellas imágenes en las que no se pueden reconocer puntos de control, como imágenes marinas o con una amplia cobertura nubosa o bien sean imágenes con una resolución espacial en la que no se puedan establecer puntos de control con garantías. Por esta última razón es el tipo de corrección geométrica indicada para sensores de muy baja resolución espacial como los de plataforma de órbita geoestacionaria.

El método de corrección a partir de puntos de control requiere de la intervención humana, lo que resulta tedioso en comparación con el primer método. En cambio ofrece mayor precisión en la corrección dependiendo, evidentemente, de la medida en que en la imagen se puedan detectar los puntos de control establecidos.

1.4.8. Clasificación

La clasificación es el último paso en el análisis de imágenes digitales mediante teledetección (se beneficia de los procesos de correcciones, realces y fusiones de imágenes) y de ella derivan los productos cartográficos finales en forma de mapas temáticos. El ND pasa de reflejar el nivel de reflectancia a tener un valor categórico concreto que puede etiquetarse con un tipo concreto de superficie. Se genera así cartografía temática y facilita el trato estadístico de la información.

Hay numerosos métodos de clasificación que deben cumplir los siguientes requisitos:

- Fiabilidad.

- Reproducible por otros con las mismas variables de entrada.
- Robustez. No debe ser sensible a pequeños cambios en las condiciones de entrada.
- Exhaustividad.
- Objetividad. No debe estar marcado por las decisiones del intérprete.

Uno de los problemas más comunes en la clasificación es la posible similitud entre dos o más cubiertas o inmersión de una sobre otra, que provoca que estas no se definan correctamente. Esto se podría solucionar ampliando la resolución espacial o aplicando la variable temporal a las imágenes (muy apto para discriminar masas vegetales debido a la evolución estacional). También se podría acudir a información auxiliar como topografía del terreno o tipos de suelo.

Fases de la clasificación

La clasificación consta de los siguientes puntos que dependiendo del tipo de clasificación, supervisada o no supervisada, se utilizarán de un modo u otro estas fases.

1. Fase de entrenamiento. Para la interpretación de la imagen es necesaria una experiencia previa que permita identificar las categorías según su textura, tono, tamaño o situación de los píxeles que la componen.

La finalidad de la fase de entrenamiento es definir un rango de valores de ND que en conjunto describan las características de una cubierta concreta. A esto se le llama área de entrenamiento. Una cubierta no se define únicamente por un valor de ND debido a la dispersión en el comportamiento espectral.

Se deberá seleccionar una muestra de píxeles de la imagen que representen lo más fielmente posible a la categoría de interés. A partir de esta muestra se podrán calcular los ND medios y la variabilidad de cada categoría de las bandas que intervienen en la clasificación. Por lo tanto, las áreas de entrenamiento deben estar bien identificadas, deben ser suficientemente homogéneas y deben cubrir todas las clases.

En el método supervisado, se seleccionan los píxeles representativos teniendo en cuenta la experiencia en campo o el conocimiento previo del comportamiento espectral de

las cubiertas por parte del usuario. Mientras, el método de clasificación no supervisado se basa en la búsqueda autónoma de las muestras dentro de la imagen.

El problema más común en la definición de clases es que el tipo de clase informacional que constituyen la leyenda del trabajo (e.g. tipos de suelo) no corresponda con el tipo de clasepectral, es decir que ofrecen una respuesta spectral similar. Puede darse el caso de que una cubierta esté representada por varias clases spectrales, que varias cubiertas estén representadas por una sola clase spectral o que varias clases informacionales se correspondan con varias clases spectrales ([Chuvieco Salinero, 2002](#)).

2. Fase de asignación. En esta fase a cada uno de los píxeles de la imagen se le asigna una clase obteniendo así una nueva imagen con los ND expresando una categoría temática diferente. Los criterios de asignación definen un área de dominio, en torno al centro de cada categoría. Por lo tanto, si el ND del píxel se encuentra dentro de esa área será asignado a esa clase.
3. Obtención y presentación de resultados.
4. Verificación de resultados.

Algoritmos clasificadores

Para hacer una clasificación, ya sea esta supervisada o no supervisada necesitamos conocer que tipos de algoritmos clasificadores tenemos a nuestra disposición.

Mínima distancia. También llamado vecino más próximo, vecino más cercano o *Nearest Neighbor* (NN) es el criterio más sencillo y rápido de aplicar. Se asigna el píxel a la categoría cuyo centroide de clase sea el más cercano a este. La distancia es spectral y el criterio más utilizado para medirla es la distancia euclíadiana como se muestra en la ecuación siguiente:

$$d_{x,A} = \sqrt{\sum_{i=1}^m (ND_{x,i} - \overline{ND}_{A,i})^2} \quad (1.8)$$

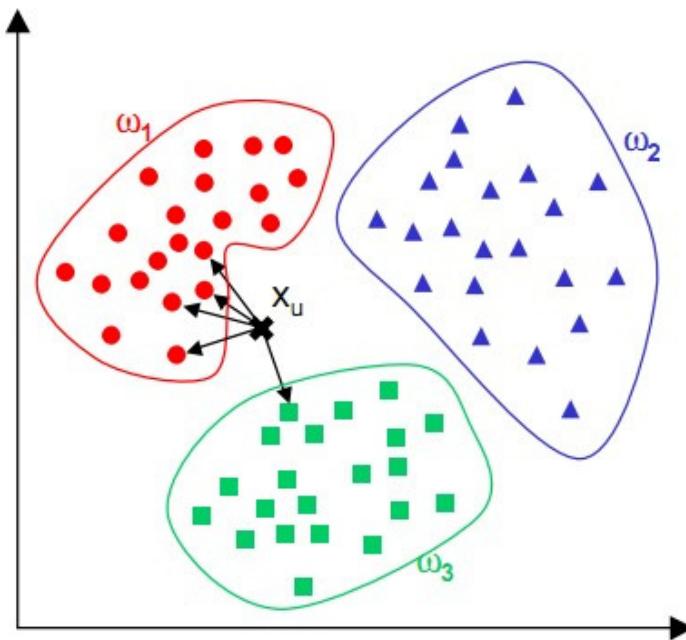


Figura 1.11: Gráfica de ejemplo del empleo del clasificador K-NN con $k = 5$.

Donde $d_{x,A}$ es la medida de la distancia espectral entre el píxel x y la categoría A ; $ND_{x,i}$ el valor del píxel en la banda i ; y $\overline{ND}_{A,i}$ el valor medio de la categoría en esa banda.

Es un clasificador eficiente cuando no se presenta solape de categorías, por lo tanto cuando la zona de estudio no es de gran complejidad. No deja píxeles sin clasificar puesto que siempre hay una clase más cercana. No considera dispersión de cada categoría o correlación entre bandas.

K-Nearest Neighbor (K-NN). Este clasificador es igual al NN con la salvedad de que pondera el valor de cada píxel en la muestra de entrenamiento por el inverso de la distancia espectral que lo separa del píxel a clasificar. En el caso del algoritmo de vecino más proximo se toma un valor $k = 1$. En la figura 1.11 se muestra una gráfica de ejemplo en la que se aplica el clasificador para dos bandas y tres categorías con módulo $k = 5$.

Casificador de paralelepípedos. Conocido también como de cajas o *multilevel-slice classifier* este clasificador permite al usuario definir un máximo y mínimo para cada clase por banda creando así cajas en el espacio n dimensional (siendo n el número de bandas) (figura




Figura 1.12: Gráfica de ejemplo del empleo del clasificador de paralelepípedos para dos bandas y tres clases. Fuente: [Olaya \(2010\)](#).

1.12). Este método puede dejar píxeles sin clasificar (los que no estén dentro de ninguna caja) y presenta problemas con el solapamiento de cajas. Para evitar esto se necesita tener un criterio de decisión.

$$C_i = (\cup \Delta x_{i-j}^t) \quad (1.9)$$

Donde C_i es el conjunto de categorías a clasificar y $\cup \Delta x_{i-j}^t$ el rango de valores radiométricos $i - j$ en cada banda t .

Máxima verosimilitud. También llamado máxima probabilidad o *Maximum Likelihood Classifier* (MLC). Este clasificador asume una distribución normal de cada clase en cada banda, estima los parámetros de distribución a partir de una muestra de entrenamiento, calcula regiones de probabilidad teórica y asigna finalmente cada píxel a la clase de mayor probabilidad. Clasifica toda la imagen no dejando píxeles sin clasificar.

En la figura 1.13 se puede ver un ejemplo en el que un píxel situado a una distancia igual del centro de la clase A al centro de la clase B es clasificado como A debido a que se encuentra dentro de una elipse de probabilidad mayor en la clase A.

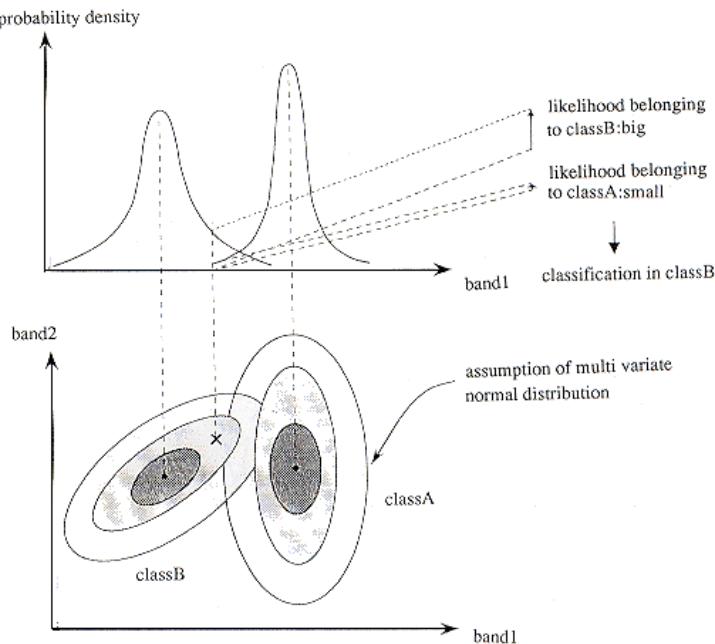


Figura 1.13: Gráfica de ejemplo del empleo del clasificador de máxima verosimilitud. Fuente: [JARS \(1999\)](#).

1.4.9. Índices de vegetación

Los Índices de Vegetación (IV) buscan mejorar la discriminación entre dos cubiertas con comportamiento reflectivo muy distinto en dos bandas, principalmente en el visible y el IRC ([Chuvieco Salinero, 2002](#)). La diferencia entre la reflectividad de la banda del rojo y la del IRC en cubiertas vegetales permite separar la vegetación sana o vigorosa de otras especies de vegetación puesto que mientras en el visible, en particular en la banda roja, los pigmentos de la hoja absorben la mayor parte de la energía que reciben, estas sustancias apenas afectan al infrarrojo cercano. Cuanto mayor sea esta diferencia de reflectividades mayor vitalidad presentará la cubierta observada debido a que en situaciones desfavorables para la vegetación menor es la diferencia.

Entre el gran número de IV desarrollados por numerosos grupos de investigación, obviando el cociente simple entre bandas (1.10), el *Normalized Difference Vegetation Index* (NDVI) (1.11) es el más utilizado en estudios de evaluación del estado vegetal creado por [Rouse et al. \(1974\)](#).

$$C_i = \frac{\rho_{i,IRC}}{\rho_{i,R}} \quad (1.10)$$

$$NDVI_i = \frac{\rho_{i,IRC} - \rho_{i,R}}{\rho_{i,IRC} + \rho_{i,R}} \quad (1.11)$$

Donde $\rho_{i,IRC}$ y $\rho_{i,R}$ indican la reflectividad de un píxel i en la banda del IRC y rojo respectivamente que son las bandas 5 y 4 del sensor OLI de Landsat 8. Los valores del NDVI en cada píxel varían entre [-1,1].

Un aspecto importante y que el NDVI no tiene en cuenta es el efecto que provoca la proporción entre vegetación y suelo del píxel. El *Soil Adjusted Vegetation Index* (SAVI) (1.12) es un IV que lo que busca es reducir este efecto aplicando una constante L de radiancia de fondo en la ecuación.

$$SAVI_i = \frac{\rho_{i,IRC} - \rho_{i,R}}{\rho_{i,IRC} + \rho_{i,R} + L} (1 + L) \quad (1.12)$$

Otra alternativa al NDVI es el llamado *Enhanced Vegetation Index* (EVI) (1.13) que corrige alteraciones de suelo y atmósfera mediante la aplicación de una serie de constantes. Este resulta más sensible que el NDVI en rangos contrastados de vegetación ([Chuvieco Salinero, 2002](#)).

$$EVI_i = Gain \frac{\rho_{IRC} - \rho_R}{\rho_{IRC} + C_1\rho_R - C_2\rho_B + L} \quad (1.13)$$

Donde ρ_B , ρ_R y ρ_{IRC} son las reflectividades de azul, rojo e infrarrojo cercano respectivamente; L es el mismo coeficiente de radiancia de fondo del índice SAVI; Gain es un factor de ganancia; y C_1 y C_2 son coeficientes de corrección de la influencia del aerosol.

Otros IV son, por ejemplo, los expuestos en el cuadro siguiente:

Cuadro 1.6: Otros tipos de IV.

Índice de vegetación	Operación
DVI Difference Vegetation Index	NIR-R
GDVI Green Difference Vegetation Index	NIR-G
GNDVI Green Normalized Difference Vegetation Index	(NIR-G)/(NIR+G)
GSAVI Green Soil Adjusted Vegetation Index	$[(NIR-G)/(NIR+G+L)]*(1+L)$

Capítulo 2

Material y métodos

2.1. Estudio radiométrico

En este caso, obtendremos del estudio radiométrico firmas espectrales del tipo mono-banda. Estas se caracterizan porque la respuesta de los objetos analizados es contenida en un solo canal continuo de datos ([Corrales Andino, 2010a](#)).

La meteorología y la difícil accesibilidad de la zona hicieron aconsejable hacer una toma de muestras y realizar la observación en un estudio. El material vegetal utilizado en el estudio fueron muestras recientes de hojas tomadas de árboles de cada especie como se describe en la metodología de obtención de firmas espectrales de [Corrales Andino \(2010b\)](#) y como se puede apreciar en las figuras [2.1](#) y [2.2](#).

2.1.1. Datos

Los datos obtenidos por el profesor Rafael Enrique Corrales con el espectro-radiómetro de campo se presentan en cuatro archivos de extensión .dat de texto simple, uno para cada especie más uno del conjunto que no se utilizará.

La característica principal de estos datos es que abarcan un amplio rango espectral de forma continuada, similar a lo que ocurre en la obtención de una imagen, pero en este caso los datos serían solamente de un punto, no de una superficie extensa. El rango espec-



Figura 2.1: Hojas de las especies de mangle a analizar. Fotografía de Rafael Corrales.




Figura 2.2: Momento de la obtención de las firmas espectrales de una especie. Fotografía de Rafael Corrales.

tral captado por el espectro-radiómetro comprende de 324.5 - 1075,5 nm almacenando la reflectividad media para intervalos de onda de 1nm.

Simultáneamente a la toma de datos se visitaron puntos donde era conocida la existencia de mangle (cuadro 2.1). Estos estrictamente no son puntos de control porque no se trata de puntos en los que no solo existe la cobertura de un tipo de mangle concreto sino que pueden confluir varias cubiertas en el mismo punto. En ellos se observaron la certeza del cambio en la existencia de mangle y alguna de las causas que lo motivan, como la presencia de salineras y estanques de camarón. En algunos casos, como el de La Brea la presencia de *R. mangle* es para reducir el impacto visual de las camaroneras. En otras zonas como en Los Ganchos, la pérdida de cobertura de mangle es debida a la dinámica de la costa provocada por la desembocadura del río Nacaome.

Cuadro 2.1: Serie de puntos conocidos de existencia de manglar con la especie predominante.

East	North	Nombre	Especies existentes
452379	1476560	Pasadero de los Pericos	<i>R. mangle</i> .
450493	1476503	Punta de los Elotes	<i>R. mangle</i> y <i>L. racemosa</i>
448571	1484829	Corinto	<i>R. mangle</i> y <i>L. racemosa</i>
438047	1488915	Jiote Grande	<i>R. mangle</i> , <i>L. racemosa</i> y <i>A. germinans</i>
434163	1487386	Los Ganchos	<i>R. mangle</i>
440251	1489561	La Brea	<i>R. mangle</i> , <i>L. racemosa</i> y <i>A. germinans</i>

2.2. Software

El uso de software libre en general es un recurso a tener en cuenta para realizar trabajos técnicos que utilizan un componente informático ([Matellán Oliveira et al. , 2004](#)) ([Mas i Hernández, 2005](#)). En concreto es uso de este tipo de software en trabajos sobre recursos medioambientales cobra importancia principalmente por, entre otras cosas:

1. Abarata el coste del proyecto al ser bajo o nulo el coste de una licencia de uso.

2. Cuenta con un buen soporte y servicio técnico llevado en algunos casos por comunidades de usuarios y a largo plazo. Se evita la obsolescencia del producto.
3. Formatos estandarizados que permiten la interoperabilidad.
4. Se centra en proporcionar un servicio y no un producto.

Este TFG se ha hecho íntegramente con software libre distribuido bajo licencia GNU GPL salvo que se indique lo contrario, utilizando los programas seguidamente mencionados sobre un sistema operativo GNU/Linux, en concreto sobre la distribución Ubuntu 14.04.

Adicionalmente se ha hecho un control de versiones remoto con el software Git¹ que, mediante repositorios, permite gestionar un historial de ficheros y carpetas recordando y organizando el contenido en cada momento documentando los cambios que ha sufrido y quién y por qué los ha realizado. Permite, por tanto, recuperar el documento a versiones anteriores o revisar el proceso de desarrollo del mismo funcionando como respaldo. De esta forma se permite el acceso a los archivos por la plataforma web GitHub de forma pública². La interfaz gráfica utilizada ha sido SmartGit (GmbH, 2015) libre y de uso gratuito para fines no comerciales y donde se pueden hacer cómodamente la mayoría de las operaciones de control de cambios.

R Para el tratamiento de los datos se ha utilizado el software estadístico de uso libre R Project for Statistical Computing, más conocido como R (R Core Team, 2013) en su versión 3.2.0. R puede definirse como un software de análisis estadísticos, como un generador de gráficos o como un lenguaje de programación. Si bien es un software pensado para su uso sobre interfaces de código, para la realización de este TFG se ha utilizado la interfaz gráfica del software libre RStudio, bajo licencia AGPL, con el fin de hacer que su uso resulte más amigable.

R, como la mayoría de software que funciona sobre sistema operativo GNU/Linux, se

¹Otra opción en lo que a control de versiones se refiere sería la del software *Subversion* (SVN) (Hernández, 2011) pero este solamente permite hacer un control local de los cambios.

²El código de este trabajo es accesible desde la página web <https://github.com/MarcosRial/TFG>

compone de módulos o paquetes que se incorporan a una base del programa, llamado *R core*, para extender sus posibilidades y funciones. Actualmente el número de paquetes de R existentes ronda los 4000, desarrollados por usuarios y programadores de todo el mundo. Esta cifra se incrementa ya que periódicamente se suben paquetes a la red de repositorios oficial *Comprehensive R Archive Network* (CRAN).

R es uno de los lenguajes más utilizados en estadística. Adicionalmente abarca otros muchos campos debido a la cantidad de librerías disponibles como tratamiento de imágenes satélite o clasificación supervisada.

GRASS GIS Para el tratado de imágenes Landsat y su posterior clasificación se utiliza el programa de SIG gratuito y de código abierto *Geographic Resources Analysis Support System* (GRASS) ([GRASS Development Team, 2012](#)). GRASS es un proyecto de la *Open Source Geospatial Foundation* (OSGeo). Es un potente software en lo que a utilización de manejo y análisis de información geoespacial se refiere. Su funcionalidad es similar a otros programas SIG como QGIS, en los cuales, mediante extensiones aplicadas a la base del programa podemos ampliar sus funciones y adaptarlas a nuestras necesidades ([Neteler & Mitasova, 2002](#)). Al igual que R, GRASS se puede utilizar mediante una interfaz de código pero se optó por la utilización de una interfaz gráfica de usuario (la propia del software) que facilita y agiliza mucho el trabajo.

La versión utilizada es la 6.4.3 estable. No obstante durante la realización de este TFG se liberaron la versión de desarrollo 6.4.4 y la versión estable 7.0 que fueron utilizadas como alternativa a la versión anterior.

LATEX En la redacción de este documento de memoria se empleó LATEX, el intérprete de TEX, lenguaje y motor de composición de textos de bajo nivel potente y versátil especialmente indicado para elaborar documentos de texto de alta calidad tipográfica. LATEX, software libre bajo licencia LPPL, es un conjunto de macros escritas en lenguaje TEX para la realización de múltiples tareas en lo que a la redacción de un documento de texto se refiere ([Hernández, 2011](#)) ([Galindo Riaño et al. , 2001](#)) ([Lamport, 1994](#)).

Como editor se utilizó TeXMaker ([Brachet, 2003-2014](#)), un entorno integrado de edición libre que facilita la redacción, edición, compilación y revisión del documento.

Para la gestión de la bibliografía, las referencias cruzadas y que fuera correctamente incluida en este documento se ha utilizado el software libre JabRef. Este software compila la bibliografía mediante BibTeX, el formato estándar de bibliografía de \LaTeX .

2.3. Técnicas de análisis espectral

Las técnicas de separabilidad empleadas en este TFG serán: codificación binaria e índice de acuerdo espectral, clasificación angular y *continuum removal*. Se utilizarán para ello diversas funciones creadas en el lenguaje de programación R que se aplicarán a los datos tomados en campo.

2.3.1. Índice de acuerdo espectral

Con el fin de cuantificar de alguna forma la similitud entre los espectros de dos cubiertas a priori diferentes, podemos aplicar lo que se llama Índice de Acuerdo Espectral (IAE) ([Chuvieco Salinero, 2002](#)), que viene dado por la siguiente expresión:

$$IAE = \frac{\sum_{k=1}^m (CB_{i,k} - CB_{j,k})^2}{m} \quad (2.1)$$

Siendo $CB_{i,k}$ la codificación binaria del espectro i para cada banda k , $CB_{j,k}$ la codificación binaria del espectro j para cada banda k y m el número de bandas.

Este método de cuantificación está basado en una codificación binaria (0 y 1) del espectro para cada banda. Cuanto más cercano sea el valor del IAE a 0, los espectros serán más similares, al contrario que cuanto más se aproxime el valor a 1. De esta forma no solo se puede obtener un análisis cuantitativo de la similitud entre dos espectros, sino que también

```

1 IAE <- function(i, j) {
2
3   mediai = mean(i$V5) # media de las observaciones de reflectividad
4   CBi = sapply(i$V5, FUN=function(x) {if(x>=mediai) {1} else {0}})
      # creacion de la codificacion binaria
5
6   mediaj = mean(j$V5)
7   CBj = sapply(j$V5, FUN=function(x) {if(x>=mediaj) {1} else {0}})
8
9   Indice = sum((CBi-CBj)^2)/length(CBi) # aplicacion del indice
10  return(Indice)
11 }

```

Figura 2.3: Script de la función del Índice de Acuerdo Espectral en R. Fuente: Elaboración propia.

podremos realizar un análisis a simple vista realizando gráficas de la clasificación binaria de cada espectro.

En la figura 2.3 se muestra el script de la función en R a la que se le aplicarán los datos de campo y que devuelve el dato de acuerdo espectral.

2.3.2. Continuum removal

El método de *Continuum Removal* (CR) o, como lo cita Chuvieco Salinero (2002), análisis de absorción diferencial frente a la tendencia, es una técnica de análisis en la que se marcan en cada observación los valores máximos relativos o locales de reflectividad. Estos máximos sirven como indicadores de tendencia de la observación. Esta técnica busca eliminar el efecto de albedo, permitiendo centrar el análisis en la absorción diferencial propia de cada banda. Lo analizado principalmente será la intensidad de la absorción o profundidad en cada sección de la gráfica, así como la asimetría y anchura con el fin de detectar similitudes entre dos o más muestras spectrales. Fue utilizado por primera vez en el artículo de Kokaly & Clark (1999).

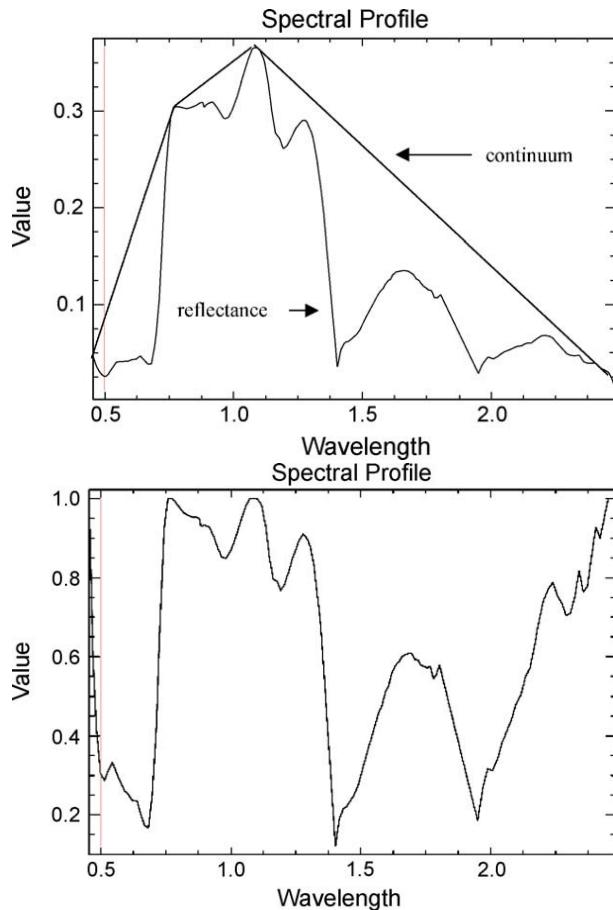


Figura 2.4: Ejemplo de aplicación de la técnica continuum removal. Fuente: Extraído de [Huang et al. \(2004\)](#).

[Huang et al. \(2004\)](#) testaron la efectividad de esta técnica para estimar el contenido de substancias químicas en hojas (de donde se extraen los ejemplos de la figura 2.4). En otro ejemplo [Filippi & Jensen \(2007\)](#) emplean el CR como utilidad para realizar clasificaciones de vegetación con imágenes hiperespectrales. Y [Underwood et al. \(2003\)](#) utiliza este método para detectar y determinar el impacto de especies forestales invasoras sobre otras especies autóctonas apoyándose también en imágenes hiperespectrales.

Este método no aporta un valor numérico de cuantificación de la similitud entre dos espectros, centrándose en un análisis gráfico de cada respuesta por separado.

El paquete base de R ya incluye las operaciones estadísticas básicas necesarias para la elaboración de la clasificación angular y el IAE con la única excepción de que para poder aplicar el analizador CR se debe descargar el paquete adicional *prospectr* ([Stevens &](#)

```

1 require(prospectr) # carga del paquete necesario
2
3 # aplicacion de la funcion implementada en prospectr
4 cr <- continuumRemoval(mangle1corte$V5, mangle1corte$V4,
5                           type="R",
6                           interpol="linear")
7
8 grafica(data1) # salida grafica a los datos iniciales
9 lines(data1$V4,cr) # superposicion de la grafica de CR

```

Figura 2.5: Script de la función de Continuum Removal en R. Fuente: Elaboración propia a partir de Stevens & Ramirez-Lopez (2014).

Ramirez-Lopez, 2014).

En la figura 2.5 se muestra el script original de la función en R a la que se le aplicarán los datos de campo y que devuelve la gráfica de CR.

Se puede observar como mediante el comando inicial `require()` se llama al paquete `prospectr`, gracias al cual nos aseguramos que está correctamente cargado el paquete necesario para realizar las operaciones que siguen en el script (Stevens & Ramirez-Lopez, 2014). Para ello se utilizó el instalador de paquetes de RStudio, localizando el paquete requerido en el repositorio oficial de RCAN e instalando las dependencias necesarias, que también se podría haber hecho con el comando “`install.packages()`”. El comando `grafica()` es la llamada a una función creada para presentar la gráfica a nuestro gusto, mientras que con el comando `lines()` se nos permite superponer la gráfica de CR a la anterior.

Para el correcto funcionamiento del análisis se procedió a crear una matriz de 3x481 donde las filas corresponden a las tres especies analizadas y las columnas al valor de longitud de onda. El fin es el de presentar de mejor forma los datos en la función de CR de R y aunque el resultado es el mismo, que haciéndolo una por una, nos permite obtener este de forma más rápida y con menos pasos.

El script original de la función en R previamente presentado en la figura 2.5 sufre cam-

bios, quedando de la siguiente manera:

```

1 require(prospectr)
2
3 # generacion de la matriz de datos
4 matriz <- matrix(c(RhizophoraCorte$V5 , LagunculariaCorte$V5 ,
5
6 AvicenniaCorte$V5) ,
7
8 byrow=TRUE ,
9
10 nrow=3 ,
11 ncol=481)
12
13 # se especifica el numero de observaciones
14 bandas <- manglencorte$V4
15
16 # se aplica la funcion
17 cr <- continuumRemoval(matriz , bandas)
18
19 # salida grafica a los datos
20 matplot(bandas , t(matriz) ,
21 type="l" , ylim=c(0 , 1))
22 matlines(bandas , t(cr2))

```

Figura 2.6: Script modificado de la función de Continuum Removal escrita en R. Fuente: Elaboración propia.

Donde “manglencorte” es el archivo de datos con el corte realizado para cada especie como se explicó anteriormente. Se crea un objeto llamado “bandas” tomando los valores de la fila V4 de cualquiera de los archivos de datos. Se crea la gráfica con el comando *matplot()* y con *matlines()* se superpone la gráfica propia del método CR.

2.3.3. Clasificación angular

La clasificación angular también llamada *Spectral Angle Mapping* (SAM) calcula la similitud entre dos espectros a partir de su distancia angular espectral. Originalmente este método compara espectros desconocidos con otros de referencia tomados, por ejemplo, de bibliotecas espectrales o de la misma imagen ([Girouard et al. , 2004](#)) con el fin de asig-

```

1 AE <- function(i,j) {
2
3   Ri = i$V5 # valores de las observaciones
4   Rj = j$V5
5
6   # calculo del angulo espectral para dos cubiertas
7   angulo = acos (sum(Ri*Rj)/(sqrt(sum(Ri^2))*sqrt(sum(Rj^2))))
8   return(angulo)
9 }
```

Figura 2.7: Función de clasificación angular en R. Fuente: Elaboración propia.

nar píxeles desconocidos a clases de referencia conocida en una clasificación temática. El algoritmo de clasificación angular es el siguiente:

$$\theta = \arccos \frac{\sum_{k=1}^m \rho_{i,k} \rho_{j,k}}{\sqrt{\sum_{k=1}^m \rho_{i,k}^2} \sqrt{\sum_{k=1}^m \rho_{j,k}^2}} \quad (2.2)$$

Siendo $\rho_{i,k}$ la reflectividad del espectro i en una banda k , $\rho_{j,k}$ la reflectividad del espectro j en la misma banda y m el número de bandas.

Los espectros serán más similares cuanto menor sea el valor del ángulo θ de la ecuación 2.2.

En la figura 2.7 se muestra el script de la función en R a la que se le aplicarán los datos de campo y que devuelve el valor del ángulo θ .

2.4. Imágenes de satélite

2.4.1. Landsat 8

Landsat 8 dispone de 11 bandas espectrales: 9 del sensor OLI (expuestas en la tabla 1.4) y 2 del sensor *Thermal Infrared Sensor* (TIRS) que no son de interés para este trabajo.

Como los datos del radiómetro de campo solo abarcan las longitudes de onda comprendidas entre 325nm y 1075nm solo son de interés las cinco primeras bandas que se detallan a continuación:

- Banda 1 (Coastal/Aerosol) [430-450 nm]: Detecta azules y violetas intensos. Solventa los problemas de la dispersión de Rayleigh. Facilita la detección de la calidad de aguas poco profundas y partículas de polvo o aerosol en la atmósfera.
- Banda 2 (Blue) [450-510 nm]: Detecta el azul del espectro visible. Útil para diferenciar el suelo desnudo de la vegetación y detectar zonas pavimentadas como carreteras o áreas urbanas.
- Banda 3 (Green) [530-590 nm]: Detecta el verde del espectro visible. Sensible al nivel de turbidez del agua. Brillante en zonas de tierra árida y oscura en zonas boscosas o de cultivos.
- Banda 4 (Red) [640-670 nm]: Detecta el rojo del espectro visible. Útil en la clasificación de zonas vegetales pero no diferencia estas de agua, puesto que aparecen como zonas oscuras.
- Banda 5 (NIR) [850-880 nm]: Detecta el infrarrojo cercano. Especialmente importante en ecología porque la vegetación vigorosa la refleja. Útil para la obtención del NDVI y distinguir tipos de vegetación.

2.4.2. Obtención de las imágenes

Las imágenes se obtuvieron del servicio Earth Explorer, de la EROS de la USGS. Estas imágenes ya vienen con una corrección geométrica previa hecha, por lo que no será necesario aplicar más correcciones de este tipo. En un archivo .txt asociado a las imágenes .tiff para cada banda se especifica que el método de corrección geométrica utilizado ha sido el de convolución cúbica.

En concreto, los archivos que nos ofrece el servicio de descargas son:

- Una imagen en composición de color natural como las que se muestran en la figura [2.8](#).

- Una imagen térmica que no nos será de utilidad.
- Una imagen de 8 bits que cuantifica la calidad de la observación.
- Las imágenes anteriormente citadas georreferenciadas.
- Las imágenes correspondientes a cada banda de Landsat 8 con la corrección geométrica aplicada (level 1) en formato GeoTIFF.

Se trata de un producto de *Level 1 Terrain* (L1T) con correcciones geométricas sistemáticas aplicadas utilizando para ello puntos de control terrestre o información de posición integrada a bordo ([Ariza, 2013](#)). Se entrega así una imagen registrada a la proyección WGS84. Adicionalmente en este nivel de producto contiene una corrección topográfica por el desplazamiento del terreno debido al relieve. Las imágenes se encuentran en formato de ND que se pueden transformar a valores de reflectividad *Top of Atmosphere* (TOA) en las bandas 1 a 9.

Otra forma de obtener las imágenes de Landsat 8 es mediante el gestor de descargas Libra, que aprovecha la API del servicio de *Amazon Web Services* (AWS) que aloja estas imágenes desde septiembre de 2014. Este nos permite elegir qué bandas descargar, ahorrando tiempo en la operación.

En cambio, para la correcta realización de este TFG donde tenemos datos de reflectividad a nivel del suelo, necesitamos que las imágenes Landsat también muestren valores de reflectividad a ese nivel. Esto se consigue aplicando un algoritmo de corrección radiométrica a las imágenes L1T obteniendo un producto también proporcionado por la agencia EROS bajo demanda llamado *Provisional Landsat 8 Surface Reflectance* (PL8SR) ([USGS, 2015](#)) que también se puede encontrar bajo en nombre de Landsat SR.

Para abarcar la zona de estudio se necesitaron obtener dos imágenes que tienen las características mostradas en el cuadro 2.2. Se consideró que la diferencia temporal entre ambas imágenes y la fecha de toma de datos no era determinante suponiendo un escaso cambio fenológico de las especies de mangle en ese periodo de tiempo.



(a) Imagen Landsat path 18 row 51 (23/11/14) (b) Imagen Landsat path 17 row 51 (19/12/14)

Figura 2.8: Imágenes Landsat con corrección geométrica utilizadas para el trabajo. Fuente: USGS.

Cuadro 2.2: Características de las imágenes Landsat obtenidas (figura 2.8).

Imagen	Path	Row	Fecha	West	East	North	South
1 (a)	18	51	23/11/2014	-89.105062	-86.987819	14.067713	11.946409
2 (b)	17	51	19/12/2014	-87.549399	-85.443030	14.062287	11.952632

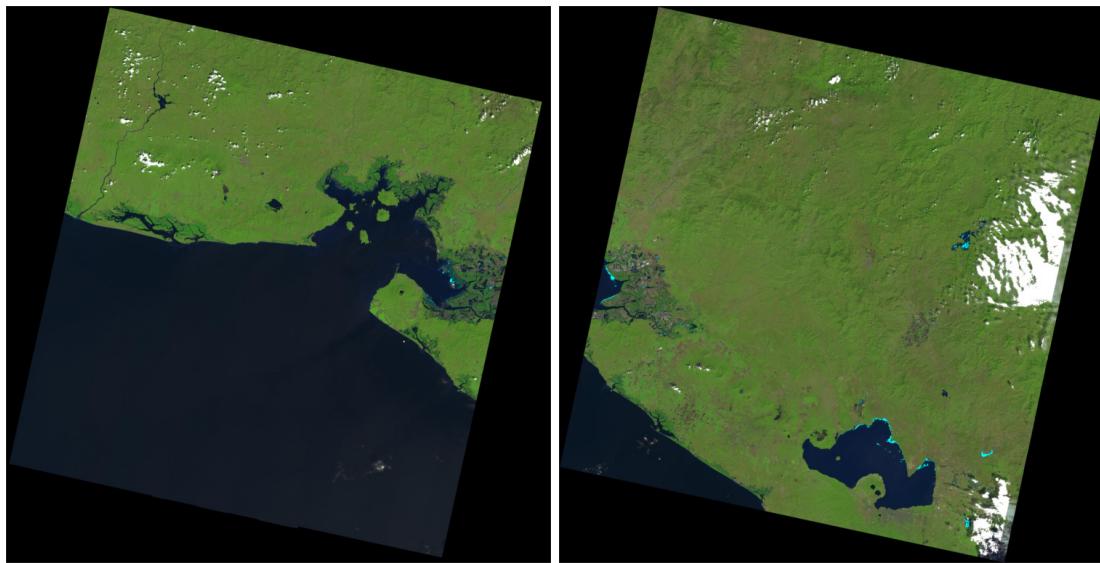
Se observa en las imágenes de calidad de la figura 2.9, en las que las nubes y nubes altas se marcan de color blanco y amarillo respectivamente, que la cobertura nubosa es aceptable para trabajar en la zona de estudio.

Las imágenes utilizan el siguiente código de identificación en el nombre ([Ariza, 2013](#)) ([USGS, 2015](#))

LXSPPRRYYDDGSIVV

donde:

- L: Landsat.
- X: Sensor.



(a) Imagen de calidad Landsat path 18 row 51
(06/10/14) (b) Imagen de calidad Landsat path 17 row 51
(16/11/14)

Figura 2.9: Imágenes de calidad de Landsat de 8 bits. Fuente: USGS.

- S: Satélite.
- PPP: Path.
- RRR: Row.
- YYYY: Año de adquisición de la imagen.
- DDD: Día juliano del año.
- GSI: Identificador de la estación terrestre de seguimiento.
- VV: Versión del archivo.

2.4.3. Tratamientos previos

Como se decía en el apartado anterior, la geometría de las imágenes ya está corregida. Pero es necesario realizar algunos procedimientos antes de unirlas y recortarlas finalmente para que se adapten a la zona de estudio y sea más cómodo trabajar con ellas. Estos procedimientos son el tratamiento de los valores nulos, la transformación de los ND en re-

flectancias, el mosaico de imágenes, su posterior recorte y la aplicación de un filtro de paso bajo.

Lo primero que se debe hacer en GRASS es crear la localización (*location*) de nuestro proyecto y añadir las imágenes al directorio de mapas (*mapset*). Los datos de la localización se establecen gracias a la lectura por parte de GRASS de la configuración de proyección y datum de un archivo de datos georreferenciado, es decir, de cualquier imagen de Landsat del trabajo. Las imágenes se añadirán al *mapset* con el comando *r.in.gdal*.

Valores nulos

El tratamiento de los valores nulos se lleva a cabo mediante el comando *r.null* como sigue:

```
r.null map=LC80180512014279LGN00_B1@TFG setnull=0 null=-9999
```

Figura 2.10: Tratamiento de valores nulos en GRASS con el comando *r.null*.

donde “*map*” corresponde a la banda a tratar seguido por el *mapset*, “*setnull*” indica el valor de los elementos nulos y “*null*” indica el nuevo valor de estos elementos. Se elige un valor de -9999 para evitar posibles errores de realizarse, por ejemplo un NDVI que trabaja con valores de píxel de [-1,1].

Este no es un procedimiento obligatorio aunque recomendable ya que los geoprocesos aplicados siguientes, como el mosaico de imágenes, ya implican un tratamiento de valores nulos.

Mosaico de imágenes

Para realizar el mosaico de las dos imágenes de las que disponemos tenemos dos opciones: utilizando la herramienta *gdal_merge.py* y hacerlo en GRASS. Para utilizar la herramienta de la librería *Geospatial Data Abstraction Library* (GDAL) *gdal_merge.py* debemos tener las siguientes consideraciones previas:

- Es un método que se ejecuta en la terminal de Linux. Para un método guiado se utilizaría, por ejemplo, la herramienta *raster/combinar* en QGIS o el método de GRASS que se expondrá más adelante.
- Las dos imágenes deben estar en el mismo sistema de coordenadas.
- Utiliza como método de remuestreo el de vecino más próximo.
- La última imagen de la lista será copiada sobre la precedente en el caso de haber solape.

La línea de comando en cuestión es la siguiente (para las imágenes de la primera banda y en el caso de tener situadas las imágenes en la misma carpeta):

```
gdal_merge.py -n 0 -v LC80170512014320LGN00_B1.TIF
LC80180512014279LGN00_B1.TIF -o mosaico1.tif
```

Figura 2.11: Mosaico de imágenes con herramientas GDAL.

En este caso se utilizan los comandos asociados u opciones siguientes: *-n* para que se ignoren los píxeles con valores nulos, *-v* para que se detallen las operaciones realizadas y *-o* que permite dar nombre al archivo de salida. Con este método no sería necesario realizar el tratamiento de valores nulos.

En la figura 2.12 se observa el diálogo resultante de la operación anterior que confirma que se ha hecho bien el mosaico. En el tenemos datos de las imágenes como el nombre, las coordenadas de la esquina superior izquierda e inferior derecha, tamaño del píxel y tiempo que se necesitó para realizar la operación.

De hacerlo en GRASS, el comando sería *r.patch*, con la salvedad de que las dos imágenes deben estar en la misma región de cálculo, la cual se puede ver en el cuadro 2.3, quedando la línea de orden de la figura 2.13.

Recorte de la imagen

Para trabajar solamente con la zona de estudio es necesario recortar la imagen o reducir la región de cálculo. Para ello empleamos las opciones de visualización de GRASS con una

```

Processing file 1 of 2, 0.000% completed.
Filename: LC80170512014320LGN00_B1.TIF
File Size: 7581x7761x1
Pixel Size: 30.000000 x -30.000000
UL:(440385.000000,1554615.000000) LR:(667815.000000,1321785.000000)
Copy 0,0,7581,7761 to 5590,20,7581,7761.

Processing file 2 of 2, 50.000% completed.
Filename: LC80180512014279LGN00_B1.TIF
File Size: 7611x7791x1
Pixel Size: 30.000000 x -30.000000
UL:(272685.000000,1555215.000000) LR:(501015.000000,1321485.000000)
Copy 0,0,7611,7791 to 0,0,7611,7791.

real    0m2.820s
user    0m2.239s
sys     0m0.521s

```

Figura 2.12: Diálogo resultante del mosaicado de las imágenes en la terminal de Linux. Fuente: Elaboración propia.

```

r.patch input=LC80180512014327LGN00_sr_band1@TFG,
          LC80170512014352LGN00_sr_band1@TFG
output=Mosaico_B1

```

Figura 2.13: Mosaico de imágenes en GRASS mediante el comando r.patch.

extensión de coordenadas superior derecha de (516000 , 1501230) e inferior izquierda de (377940 , 1412100) como se muestra en el cuadro 2.3. Una vez fijada se selecciona la opción de zoom “set computational region from display extent” que simplemente reduce la región de cálculo previamente establecida a la extensión de la visualización actual y nos permite realizar operaciones en esta.

Con el comando *r.resample* se hace el remuestreo mediante vecino más próximo del área del recorte permitiendo obtener la imagen final para cada banda. El comando se emplea de la siguiente forma para cada banda:

```

r.resample input=MosaicoB1@TFG output=L8GF_SR1

```

Figura 2.14: Recorte de la imagen en GRASS con el comando r.resample.

A la hora de nombrar la imagen resultante en el *output* ya se busca un código que identifique facilmente la imagen. En este caso L8GF quiere decir que se trata de una imagen Landsat 8 del Golfo de Fonseca exclusivamente, mientras que SR1 quiere decir que se trata de una imagen con reflectividades a nivel de suelo de la banda 1.

Cuadro 2.3: Datos de las regiones de trabajo establecidas en GRASS.

	Extensión original	Extensión reducida
Proyección	1 (UTM)	1 (UTM)
Zona	16	16
Datum	WGS84	WGS84
Elipsoide	WGS84	WGS84
Norte	1555215	1501230
Sur	1321485	1412100
Oeste	272685	377940
Este	667815	516000
Res. esp. vertical (m)	30	30
Res. esp. horizontal (m)	30	30
Filas	7791	2971
Columnas	13171	4602
Celdas	102615261	13672542

Filtro de paso bajo

La aplicación de un filtro de media a la imagen Landsat de la zona de estudio permite eliminar ruido y disminuir contrastes ([Aldalur & Santamaría, 2002](#)). Antes de aplicar el filtro conviene realizar una copia de seguridad de la imagen debido a que se van a modificar los valores de reflectividad originales. Para ello se emplea el comando *r.out.gdal* que permite exportar las imágenes a formato GeoTIFF.

Se aplica a la imagen la siguiente función en cada píxel:

$$g(x, y) = \frac{1}{9} \cdot \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \quad (2.3)$$

donde $g(x, y)$ es el nuevo valor del píxel localizado en las coordenadas x e y de la imagen y la matriz refleja la dimensión 3x3 del filtro, afectando así a $g(x, y)$ solamente los valores

de los píxeles vecinos.

La operación es realizada en GRASS mediante el comando *r.neighbors* como sigue:

```
r.neighbors input=L8GF_SRFB1@TFG output=L8GF_SRFB1 size=3
```

Figura 2.15: Filtro de paso bajo en GRASS con el comando r.neighbors.

El comando admite varias operaciones de filtrado como entre otras: media, mediana y moda. Al no especificar ninguna opción extra en el comando más que el tamaño de matriz de filtrado que se aplica, GRASS aplica el método de media por defecto. En el código de nombre de la imagen se va a añadir una F para indicar que las imágenes están filtradas.

El resultado de estos tratamientos se puede ver en las figuras [2.16](#) y [2.17](#).

2.5. Clasificación de imágenes

Con las figuras [2.16](#) y [2.17](#) del apartado anterior, composiciones en color real y falso color respectivamente, se puede observar como efectivamente el bosque de mangle se sitúa a lo largo de toda la costa del golfo adentrándose unos kilómetros al interior. Lo que se busca con la clasificación es reafirmar este hecho así como detectar de forma más clara esas zonas donde la proliferación de estanques de cría de camarón y salineras están afectando al ecosistema del manglar.

Puesto que los datos disponibles no permiten la aplicación de un clasificador como el de paralelepípedos, ideal para utilizar valores estadísticos extraídos del análisis de datos, se procedió a emplear el MLC para una clasificación supervisada y no supervisada y el clasificador SAM para una segunda clasificación no supervisada. Debido a esto se incluyeron en el grupo de imágenes las correspondientes a las bandas 6 y 7 de Landsat 8 que servirán para refinar la clasificación. Un paso previo a la clasificación es la creación de un grupo y subgrupo de imágenes con el comando *i.group* que en este caso reciben el mismo nombre: L8GF.

Para la primera clasificación no supervisada se empleó inicialmente el comando *i.cluster*



Figura 2.16: Resultado de la imagen en una composición de color real (4-3-2). Imagen exportada de GRASS.
Fuente: Elaboración propia.



Figura 2.17: Resultado de la imagen en una composición de falso color (5-4-3). Imagen exportada de GRASS.
Fuente: Elaboración propia.

(figura 2.18) para crear la agrupación o *cluster* de entrada con las firmas resultantes y posteriormente se aplicó el clasificador MLC con *i.maxlik* (figura 2.19). Donde una vez especificado el grupo y subgrupo de las imágenes se debe dar nombre al archivo de firmas y el número de clases. Se decidió utilizar solamente 6 clases dado que lo realmente importante para el trabajo es definir esas zonas donde existe cobertura de mangle y un mayor número daría lugar a confusión y la necesidad de realizar una reclasificación para reducir el número de clases.

```
i.cluster group=L8GF@TFG subgroup=L8GF
signaturefile=firmas1 classes=6
```

Figura 2.18: Generación de firmas para la clasificación no supervisada con *i.cluster*.

```
i.maxlik group=L8GF@TFG subgroup=L8GF
signaturefile=firmas1 output=clasnosp
```

Figura 2.19: Aplicación del clasificador MLC con *i.maxlik*.

Para la clasificación supervisada se necesita crear una serie de áreas de entrenamiento primero como capa vectorial para posteriormente transformarla a capa ráster (detalle en figura 2.20) con el fin de agrupar los píxeles cuyo valor servirá para generar el archivo de firmas con el comando *i.gensigset* de forma similar a *i.cluster*. Previamente debemos crear en la base de datos asociada a la capa de entrenamiento dos nuevas categorías obligatorias referentes al número de categoría y nombre y una opcional referente a la tabla de color que se tomará para realizar el mapa (cuadro 2.4). Al hacer la transformación se debe especificar cada una de estas categorías en el comando *v.to.rast* como se muestra en la figura 2.21.

Para realizar la clasificación aplicando el SAM se recurrió a un script en R con la función del algoritmo implementada. Para el correcto funcionamiento del script se necesita tener instalado y funcionando los paquetes oficiales *raster*, *rgdal* y *sp* con el fin de que R permita la carga de archivos raster tipo *Tagged Image File Format* (TIFF) y hacer operaciones con ellos.



Figura 2.20: Detalle de las áreas de entrenamiento tomadas sobre imagen en falso color. Imagen exportada de GRASS.

```
v.to.rast input=vtraining@TFG output=rtraining  
use=attr attribute_column=cat  
rgb_column=color label_column=class
```

Figura 2.21: Conversión de capa vectorial a ráster de las áreas de entrenamiento con el comando v.to.rast.

```

1 require(rgdal)
2 require(raster)
3
4 # Carga de imagenes Landsat. Bandas 1-7
5 b1 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B1.TIFF")
6 b2 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B2.TIFF")
7 b3 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B3.TIFF")
8 b4 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B4.TIFF")
9 b5 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B5.TIFF")
10 b6 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B6.TIFF")
11 b7 <- raster("/home/marcos/TrabajoFinGrado//L8GF_B7.TIFF")
12
13 # Agrupamiento en un stack
14 imagen <- stack(b1,b2,b3,b4,b5,b6,b7)
15
16 # Funcion para calcular el SAM
17 SAM <- function(imagen) {
18   ref=c(m1,m2,m3,m4,m5,m6,m7) #A sustituir por los valores medios
19   de reflectividad por banda
20   sam=acos(sum(ref*imagen)/(sqrt(sum(ref^2))*sqrt(sum(imagen^2))))
21   )
22
23 # Aplicando la funcion
24 imagen2 <- calc(imagen, SAM)

```

Figura 2.22: Script de la función de Spectral Angle Mapper en R. Fuente: Elaboración propia.

Cuadro 2.4: Base de datos asociada a la capa vectorial de áreas de entrenamiento.

cat	class	color	n_cells
1	Mangle	0:128:0	4139
2	Esteros	139:105:20	3789
3	Agricultura	255:255:0	6784
4	Estanque	173:216:230	3139
5	Vegetación	144:238:144	3246

2.6. Índices de vegetación

Con los índices de vegetación propuestos a continuación se busca esclarecer más las clasificaciones anteriores. Se decidió aplicar los índices NDVI, EVI y SAVI. Simplemente con la calculadora de mapas ráster de GRASS (*r.mapcalc*) ingresando el cociente de mapas correspondiente se obtienen las tres capas referentes a los IV solo necesitando aplicar una nueva tabla de color con *r.colors*.

A las ecuaciones del EVI y el SAVI, expuestas en la sección 1.4.9, se aplicaron los valores siguientes: $L = 1$ en ambos casos; $Gain = 2,5$; $C_1 = 6$ y $C_2 = 7,5$ según lo estudiado por [Carvacho Bart & Sánchez Martínez \(2010\)](#) y [Crespo et al. \(2000\)](#).

Capítulo 3

Resultados

3.1. Análisis de separabilidad

3.1.1. Análisis visual

Una vez introducidos los datos en R se obtienen las gráficas mostradas en la figura 3.1, donde se expresan con las letras C, B, G, R e IRC la nomenclatura de las bandas de Landsat 8 ya expuestas en la sección de imágenes satélite del capítulo anterior.

Como se aprecia, los datos presentan unas alteraciones al inicio y al final que son propias del radiómetro de campo. Se procedió a desechar estos datos haciendo un corte de colas entre los valores 420 nm y 900 nm de longitud de onda para preservar lo máximo posible




Figura 3.1: Gráfica conjunta de las tres firmas espectrales. Fuente: Elaboración propia.

la integridad de los datos y que no afectaran a los análisis de separabilidad. El número de observaciones se reduciría a 481 por las 751 originales. Las gráficas resultantes son las mostradas en las figuras 3.2 y 3.3.

Las tres especies tienen un máximo local en la banda correspondiente al verde (G), típica de las especies vegetales, así como otro máximo de mayor valor, correspondientes al intervalo de longitud de onda (λ) en el que está incluida la banda del IRC. Este último máximo también es característico de la vegetación e indicaría su grado de salud.

Por lo tanto el primer vistazo a las gráficas es el esperado, siendo lo más preocupante el aparente parecido entre las especies *R. mangle* y *A. germinans*, que solo se diferencian en los valores del rango del IRC.

En el cuadro siguiente (3.1) se pueden apreciar los valores medios de cada especie para cada banda de Landsat 8.

Cuadro 3.1: Valores medios para cada banda Landsat. Fuente: Elaboración propia.

Especie	Banda 1 (C)	Banda 2 (B)	Banda 3 (G)	Banda 4 (R)	Banda 5 (IRC)
<i>R. mangle</i>	0.0540	0.0561	0.0980	0.0595	0.6895
<i>L. racemosa</i>	0.1647	0.1821	0.3345	0.1930	1.0445
<i>A. germinans</i>	0.0355	0.0479	0.1218	0.0604	0.5513

3.1.2. Índice de Acuerdo Espectral

Una vez aplicando el script con la función de IAE creado en R (figura 2.3) ya se aprecia que el resultado no es muy bueno aunque esperado, siendo las diferencias casi inapreciables como se ve en la tabla 3.2.

Las diferencias en este método son bajas debido a que se trata de tres especies que, aunque no sean de la misma familia, si son vegetales y coexisten formando asociación en el mismo ecosistema. De haber estudiado la diferencia entre especie vegetal, suelo y agua por

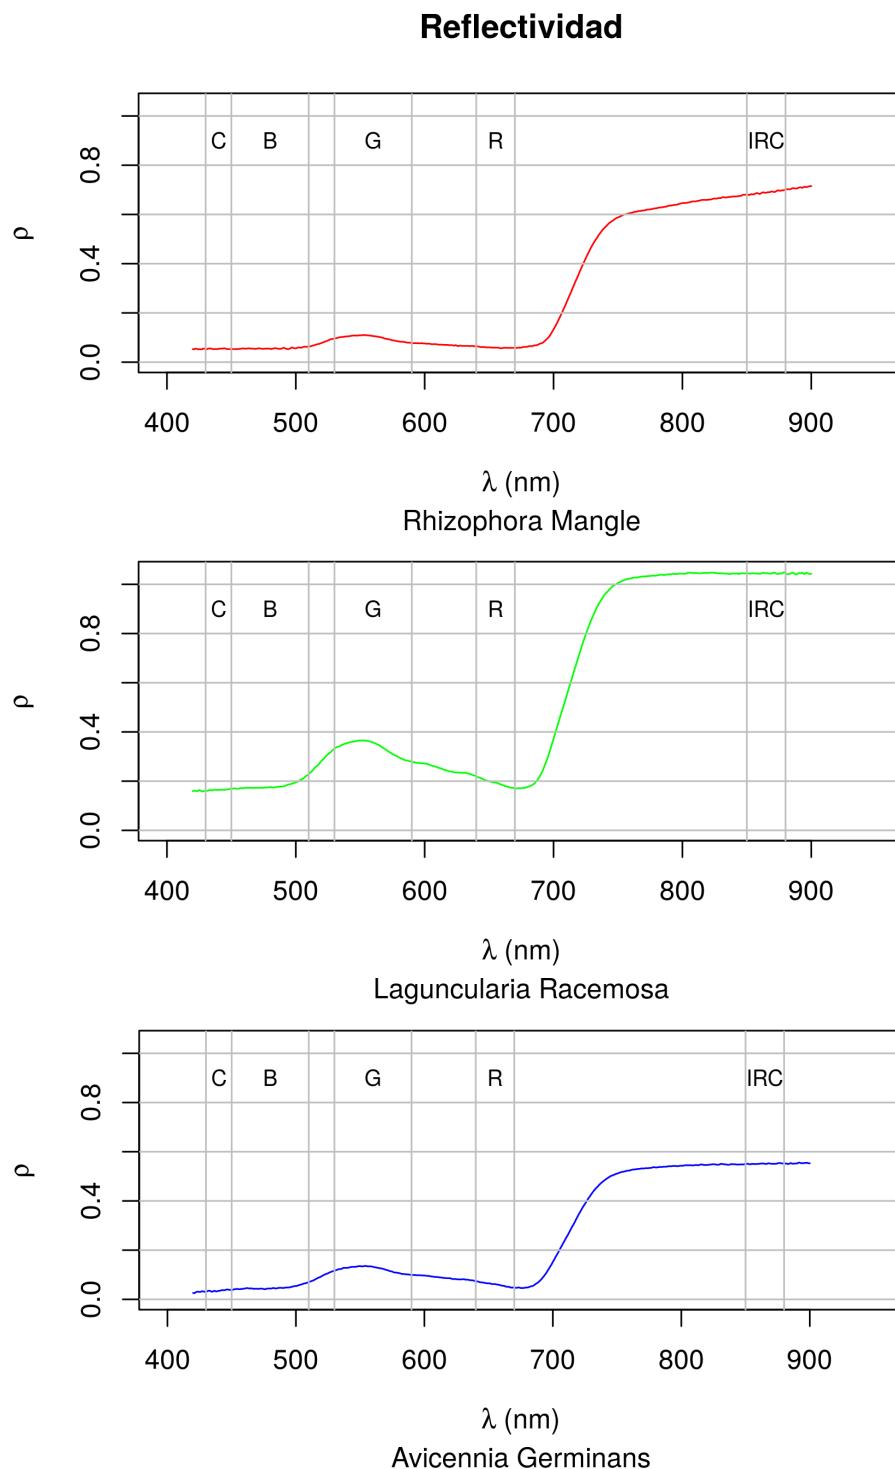


Figura 3.2: Gráficas de las firmas espectrales de las especies de mangle estudiadas una vez realizado el corte de los datos. Fuente: Elaboración propia.

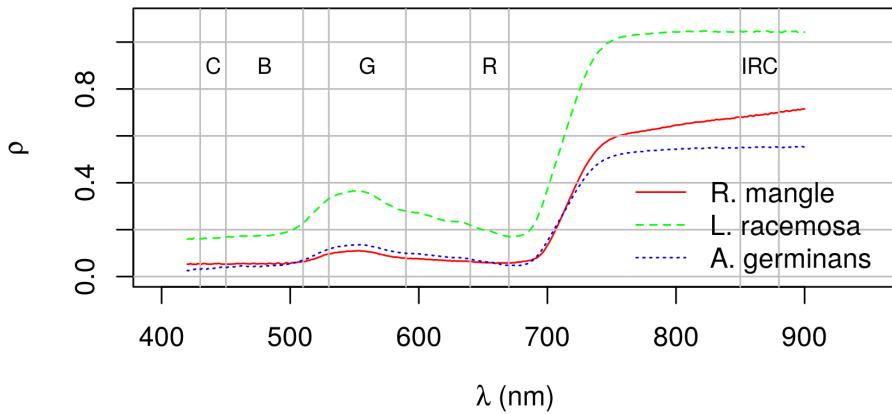


Figura 3.3: Gráfica conjunta de las tres firmas espectrales una vez realizado el corte de los datos. Fuente: Elaboración propia.

Cuadro 3.2: Valores de IAE para cada par de especies de mangle. Fuente: Elaboración propia.

	<i>R. mangle</i>	<i>L. racemosa</i>	<i>A. germinans</i>
<i>R. mangle</i>	—	0.0083	0.0062
<i>L. racemosa</i>	0.0083	—	0.0021
<i>A. germinans</i>	0.0062	0.0021	—

Por ejemplo, las diferencias habrían sido más notables debido a la diferencia de valor medio de la respuesta espectral. En este caso, el valor medio de las tres especies sería el mostrado en el cuadro 3.3.

El corte en λ que se menciona en el cuadro 3.3 se refiere al valor de longitud de onda a partir del cual la reflectancia es mayor a la media y por tanto se provoca una cambio en el valor binario de 0 a 1 donde, de tener un mayor rango de longitud de onda observada habría más de un cambio. Se observan unos valores similares de λ para las tres especies, pero donde sí se notan diferencias son en el valor medio de la reflectancia, siendo el de la *L. racemosa* notablemente superior al de las otras dos especies.

Cuadro 3.3: Valor medio de la respuesta espectral para cada especie.

Especie	ρ media	Corte en λ (nm)
<i>R. mangle</i>	0.2897692	714
<i>L. racemosa</i>	0.5424927	710
<i>A. germinans</i>	0.2530166	711

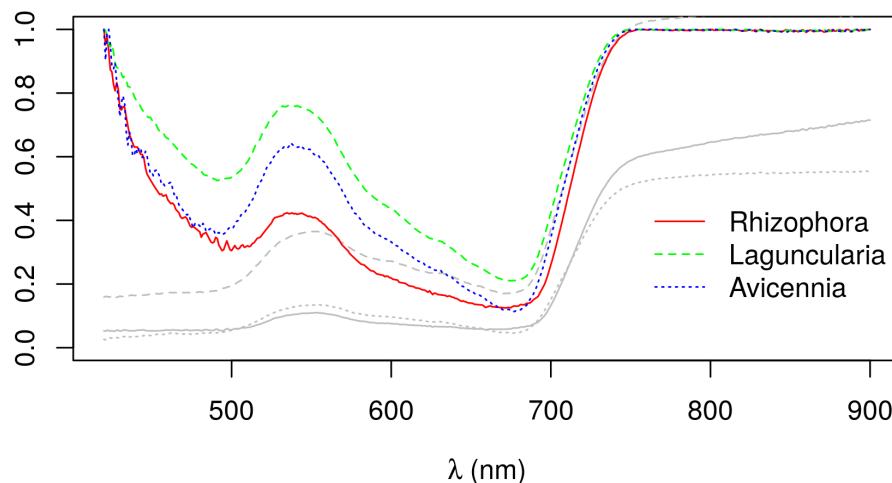


Figura 3.4: Gráfica de continuum removal para las tres especies de mangle. Fuente: Elaboración propia.

3.1.3. Continuum Removal

En la gráfica de la figura 3.4 se pueden observar las diferencias entre las tres especies que nos indica este tipo de análisis. Son tres los aspectos de esta gráfica a analizar: la profundidad y anchura de las partes convexas y la posición de los puntos mínimos. En gris la gráfica de reflectividad de cada especie.

En cuanto a la profundidad se observa una clara absorción en torno a los 490 nm y los 680 nm de las tres especies. En el caso de la *A. germinans* esta absorción es más acusada en ambos puntos. *R. mangle* y *L. racemosa* muestran un comportamiento similar en la primera zona mientras que en la segunda la *L. racemosa* no muestra la absorción de la *R. mangle*.

En cuanto a la anchura lo más llamativo es la amplitud de los valores de la *R. mangle* en torno a los valores centrales de la observación.

3.1.4. Clasificación angular

Una vez aplicado el script de R de la función de clasificación angular (figura 2.7), los valores son los de la siguiente tabla:

Cuadro 3.4: Valores del Ángulo Espectral en radianes. Ángulo centesimal entre paréntesis.

	<i>R. mangle</i>	<i>L. racemosa</i>	<i>A. germinans</i>
<i>R. mangle</i>	—	0.1651 (10.5085)	0.0752 (4.7874)
<i>L. racemosa</i>	0.1651 (10.5085)	—	0.1062 (6.7584)
<i>A. germinans</i>	0.0752 (4.7874)	0.1062 (6.7584)	—

Se puede observar una mayor separabilidad entre *R. mangle* y *L. racemosa*, siendo menor en las otras combinaciones.

3.2. Combinación de bandas

Para observar las zonas donde hay presencia de bosque de mangle basta con realizar diversas combinaciones de bandas de Landsat 8. A las figuras ya expuestas en el capítulo de materiales y métodos (figuras 2.16 y 2.17) correspondientes al color real y a un falso color con realce del IRC en el canal rojo. En las figuras 3.5 y 3.6 se muestran combinaciones que también buscan conseguir un realce del manglar. Por las propiedades de reflectividad de la cubierta combinando bandas del infrarrojo se obtienen buenos resultados para realizar un análisis visual.

3.3. Comprobación

Debemos saber si los datos de reflectividad de las especies de mangle se adaptan a los datos de las imágenes raster de Landsat 8 que se han corregido. Para ello tomamos la serie de puntos en los que se conoce la existencia de bosque de mangle (cuadro 2.1). Se creará en GRASS una capa vectorial con estos puntos a las que se le añadirán los valores raster de reflectividad de cada banda. Los pasos a seguir fueron los siguientes:



Figura 3.5: Resultado de la imagen en una composición de realce de vegetación (6-5-4). Imagen exportada de GRASS. Fuente: Elaboración propia.




Figura 3.6: Resultado de la imagen en una composición de realce de vegetación (5-6-2). Imagen exportada de GRASS. Fuente: Elaboración propia.

- Creación de una capa vectorial en blanco de nombre “puntos” y añadirla al árbol de capas. En esta capa se digitalizarán un total de 10 puntos en los que se supone la existencia de bosque de mangle.
- Crear una base de datos asociada a la capa con *v.db.addtable* asignando nuevos campos: “x” e “y” de tipo “double” que se actualizarán con las coordenadas de los puntos. También se añadirán a la tabla columnas para alojar el valor de los datos de cada una de las bandas en cada punto nombradas como B1, B2, B3, B4 y B5 de tipo “double”.
- Actualización de los campos de coordenadas mediante el comando *v.to.db* como se muestra en la figura 3.7 donde *map* designa el vectorial que tiene la tabla asociada, *option* indica que queremos actualizar coordenadas y *columns* son los nombres de las columnas de coordenadas de nuestra tabla.

```
v.to.db map=puntos@TFG option=coor columns=x,y
```

Figura 3.7: Actualización del campo coordenadas en GRASS con el comando *v.to.db*.

- Actualización de los campos de datos del raster mediante el comando *v.what.rast* como se muestra en la figura 3.8 donde *vector* indica cual es el vectorial que deseamos actualizar, *raster* es el raster del que se tomarán los datos y *column* el nombre del campo a actualizar.

```
v.what.rast vector=puntos@TFG raster=L8GF_SRFB1@TFG column=B1
```

Figura 3.8: Actualización de los campos de datos raster en GRASS con el comando *v.what.rast*.

Debido a que en la corrección utilizada en las imágenes PL8SR los valores vienen presentados con un factor de escala de 0.0001 ([USGS, 2015](#)) corresponde reescalar los valores a un intervalo 0-1 más común. Para ello se emplea la calculadora de mapas ráster de GRASS aplicando la expresión *L8GF_SRFB1@TFG · 0,0001* para cada una de las capas del proyecto. La línea de comando utilizada es la siguiente:

Se muestran los valores resultantes para cada punto en el cuadro 3.5 y su distribución en la zona de estudio en la figura 3.10.

```
r.mapcalc 'L8GF_B1=L8GF_SRFB1@TFG*0.0001'
```

Figura 3.9: Reescalado de los valores de la imagen Landsat con r.mapcalc.

Cuadro 3.5: Base de datos asociada a la capa vectorial “puntos” de la figura 3.10.

cat	x	y	B1	B2	B3	B4	B5
1	413076.12	1485451.42	0.0080	0.0102	0.0249	0.0120	0.3054
2	416539.92	1483130.35	0.0096	0.0113	0.0254	0.0137	0.2964
3	413619.63	1482194.38	0.0090	0.0108	0.0247	0.0116	0.3311
4	434978.06	1485551.73	0.0076	0.0099	0.0256	0.0124	0.3132
5	435666.27	1481906.87	0.0086	0.0109	0.0254	0.0134	0.2954
6	426223.06	1479693.58	0.0106	0.0131	0.0330	0.0173	0.2963
7	434938.70	1478948.70	0.0119	0.0146	0.0309	0.0190	0.2612
8	455289.36	1479452.68	0.0132	0.0163	0.0385	0.0268	0.2300
9	447490.46	1478621.82	0.0147	0.0187	0.0413	0.0286	0.2300
10	452584.20	1462969.61	0.0115	0.0143	0.0345	0.0209	0.2577

Para hacer una comprobación de los datos tomados en campo se superponen estos a una gráfica de cajas y bigotes extraída de los valores de los puntos de comprobación (figura 3.11). Un gráfico de este tipo consiste en una caja rectangular donde los lados verticales (en nuestro caso) muestran el recorrido intercuartílico dividido por un segmento horizontal que es la mediana. Por lo tanto, de un solo vistazo nos aporta información sobre valor central (segundo cuartil), primer y tercer cuartil. Además nos dice cuales son los valores máximo y mínimo de la distribución, que formarían los bigotes, y detecta valores desfasados en forma de puntos fuera de la caja.

Gracias a esta representación gráfica se confirma que la magnitud de los datos tomados por el espectro-radiómetro de campo están incrementados en varias décimas en la lectura media de cada banda comparados con la información de las imágenes de Landsat 8. Pese a eso se puede observar como los datos tienen un aspecto similar.



Figura 3.10: Distribución de puntos de comprobación en la zona de estudio. Fuente: Elaboración propia.




Figura 3.11: Gráfico de cajas y bigotes correspondiente a los datos de los puntos de comprobación. Se superponen los datos medios de reflectividad para cada especie en cada banda. Fuente: Elaboración propia.




Figura 3.12: Detalle de NDVI donde se ven las zonas de marisma. Imagen exportada de GRASS. Fuente: Elaboración propia.

3.4. Clasificación de imágenes

En las clasificaciones se muestra confusión de clases, mezclándose en algunos casos el mangle con otro tipo de vegetación. A excepción de la clasificación supervisada que, a pesar de que se ve un exceso de la clase denominada “Agua 2” en zonas donde no hay presencia de esta, discrimina bien la cobertura de mangle de otros tipos.

Se muestra el resultado de las clasificaciones en el anexo de mapas de este documento.

3.5. Índices de vegetación

El NDVI nos muestra más claramente zonas de marisma o aguas turbias poco profundas que se sitúan en la línea de costa (figura 3.12), justo donde hay presencia de bosque de mangle.

Gracias al índice SAVI se pueden detectar fácilmente zonas de suelo desnudo y, sobre




Figura 3.13: Detalles de SAVI donde se ven los estanques artificiales. Imagenes exportadas de GRASSS. Fuente: Elaboración propia.

todo y más interesante, zonas de estanques artificiales, ya sean para cría de camarón, salineras o mixtas. En detalle se ven estas zonas en la figura 3.13 correspondientes a dos puntos distintos de la zona de estudio.

Se muestra el resultado de los índices de vegetación en el anexo de mapas de este documento.

Capítulo 4

Conclusiones

La primera conclusión que se puede extraer de la realización de este TFG es la referente a los datos tomados en campo. Podemos concluir que para la obtención de firmas para realizar bibliotecas espectrales tomar solamente una observación de cada especie se trate de una metodología correcta. Pero a la hora de realizar un análisis de separabilidad espectral fiable y, sobre todo, para hacer el posterior volcado de los resultados del análisis a la clasificación de imágenes satélite, resultaba óptimo tener numerosas observaciones de una misma especie. De este modo se permitiría conocer más a fondo aspectos de cada especie como desviación estándar de las observaciones con un valor central para cada banda que serían datos esenciales al hacer una clasificación supervisada de las imágenes Landsat.

En cualquier caso, se preveía una dificultad el poder clasificar tres especies de mangle, que ya de por sí no están claramente separadas en el terreno, en una imagen de resolución espacial de 30 metros. Una posible solución a este problema sería el de tomar otro tipo de imagen satelital con mayor resolución espacial, como puede ser Spot o IKONOS, o realizar una fusión de imágenes combinando la mayor resolución espacial mencionada con la amplia resolución espectral de Landsat 8.

Otro aspecto a tener en cuenta es el del software. Durante las distintas fases de realización del trabajo resultaron llamativas las numerosas actualizaciones que recibió el software. Y aunque la mayoría fueron actualizaciones menores que no afectaban a funciones importantes del programa, cabe destacar que el cambio de versión no resultó un problema de

compatibilidad de archivos provenientes de versiones anteriores. En el caso de GRASS durante la realización del TFG se liberó la versión estable 7.0 solo presentando problemas de traducción haciendo confuso el uso de algún comando o proceso, pero en ningún caso presentó problemas de compatibilidad entre versiones, salvo los evidentes a la hora de abrir un proyecto hecho en la versión anterior.

Para la realización de la clasificación de las imágenes Landsat 8 se estudió la utilización de un plugin de QGIS llamado *Semi-automatic Classification Plugin* (SCP) que permite hacer una clasificación supervisada y aplicar índices de vegetación de forma guiada por una interfaz de usuario perfectamente integrada en el software. Este plugin, creado por [Congedo \(2015\)](#), permite aplicar los clasificadores SAM, el MLC y NN además de ofrecer una alternativa para obtener imágenes Landsat a las ya mencionadas en capítulos anteriores. Con el SCP podemos importar archivos de firmas espectrales de forma sencilla.

Una posible forma de mejorar la clasificación sería la de crear una máscara para la zona de más interés centrando esta en la costa del Golfo adentrándose unos kilómetros al interior. Una forma de realizar y aplicar esta máscara sería gracias al comando *r.mask* de GRASS donde la podremos crear a partir de una capa ráster o vectorial que tengamos digitalizada.

Cabe destacar también en cuanto a GRASS la utilidad de la herramienta *Map Swipe* (*g.gui.mapswipe*) que permite una mejor comparación de dos mapas superpuestos creando una cortinilla como se muestra en la figura [4.1](#). Esta herramienta se implementó en la versión 7.0.



Figura 4.1: Map Swipe de GRASS 7. Imagen exportada. Fuente: Elaboración propia.

Bibliografía

- Aldalur, B, & Santamaría, M. 2002. Realce de imágenes: filtrado espacial. *Revista de Teledetección*, 17, 31–42.
- Ariza, Alexander. 2013. *Descripción y Corrección de Productos de Landsat 8 LDCM (Landsat Data Continuity Mission)*. 1 edn. Instituto Geográfico Agustín Codazzi (IGAC).
- Bodart, Catherine, Eva, Hugh, Beuchle, René, Raši, Rastislav, Simonetti, Dario, Stibig, Hans-Jürgen, Brink, Andreas, Lindquist, Erik, & Achard, Frédéric. 2011. Pre-processing of a sample of multi-scene and multi-date Landsat imagery used to monitor forest cover changes over the tropics. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66(5), 555–563.
- Brachet, Pascal. 2003-2014. *TeX Maker: The Universal LaTeX Editor*. <http://www.xm1math.net/texmaker/>.
- Cajacuri, Miguel Ángel Laurente. 2011. Medición de la deforestación mediante percepción remota en la microcuenca río Supte, Tingo María–Perú. *Revista Internacional de Ciencia y Tecnología de la Información Geográfica*, 1–15.
- Carvacho Bart, Luis, & Sánchez Martínez, Marcela. 2010. Comparación de índices de vegetación a partir de imágenes MODIS en la región del Libertador Bernardo O'Higgins, Chile, en el período 2001-2005. *Tecnologías de la Información Geográfica: La Información Geográfica al servicio de los ciudadanos*, 728–737.
- CEPAL, Naciones Unidas. 1999. *Honduras: evaluación de los daños ocasionados por el Huracán Mitch, 1998. Sus implicaciones para el desarrollo económico y social y el medio ambiente*. Tech. rept. LC/MEX/L. 367), 26 de enero de.

Chen, Chi-Farn, Son, Nguyen-Thanh, Chang, Ni-Bin, Chen, Cheng-Ru, Chang, Li-Yu, Valdez, Miguel, Centeno, Gustavo, Thompson, Carlos Alberto, & Aceituno, Jorge Luis. 2013. Multi-Decadal Mangrove Forest Change Detection and Prediction in Honduras, Central America, with Landsat Imagery and a Markov Chain Model. *Remote Sensing*, **5**(12), 6408–6426.

Chuvieco Salinero, Emilio. 2002. *Teledetección Ambiental: La observación de la Tierra desde el Espacio*. 2010 edn. Ariel, Planeta.

CIPF. 2014. *Anuario Estadístico Forestal 2013*. Vol. 28. Instituto Nacional de Conservación y Desarrollo Forestal, Áreas Protegidas y Vida Silvestre (ICF).

Congedo, Luca. 2015 (April). *Semi-Automatic Classification Plugin Documentation (Release 4.3.0)*.

Corrales Andino, Rafael Enrique. 2010a. Catálogo de firmas espectrales de especies florales, en la Ciudad Universitaria, Tegucigalpa, Fase 1. *Revista Ciencias Espaciales*, **1**(1).

Corrales Andino, Rafael Enrique. 2010b. Catálogo de firmas espectrales de especies florales, en la Ciudad Universitaria, Tegucigalpa, Fase 2. *Revista Ciencias Espaciales*, **2**(1).

Crespo, Martín Angel Torres, Serrato, Isabel Pino, Ruiz, Laura Granado, Carmona, Arturo Fernández-Palacios, Alba, Mónica Aguilar, & Rodríguez, Esperanza Sánchez. 2000. Comparación del NDVI con el PVI y el SAVI como indicadores para la asignación de modelos de combustible para la estimación del riesgo de incendios en Andalucía. Pages 164 – 174 of: *Tecnologías geográficas para el desarrollo sostenible [Archivo de ordenador]: IX Congreso del Grupo de Métodos Cuantitativos, Sistemas de Información Geográfica y Teledetección, Alcalá de Henares*. Universidad de Alcalá.

Curran, P. 1989. *Principles of remote sensing*. Longman.

Filippi, Anthony M, & Jensen, John R. 2007. Effect of continuum removal on hyperspectral coastal vegetation classification using a fuzzy learning vector quantizer. *Geoscience and Remote Sensing, IEEE Transactions on*, **45**(6), 1857–1869.

- Galindo Riaño, Pedro, López Mesa, Miguel Ángel, Lagares Barreiro, Paula, Espina Aragón, Francisco José, Enriquez de Salamanca, José Manuel, & González Barroso, María Ángeles. 2001. *Manual de latex*. Servicio de Publicaciones, Universidad.
- Girouard, G, Bannari, A, El Harti, A, & Desrochers, A. 2004. Validated spectral angle mapper algorithm for geological mapping: comparative study between QuickBird and Landsat-TM. *Pages 12–23 of: XXth ISPRS Congress, Geo-Imagery Bridging Continents, Istanbul, Turkey*.
- Global Administrative Areas. 2012 (January). *Web GADM*. GADM.
- GmbH, Synteko. 2015. *SmartGit, a graphical Git and Mercurial client*. Salzburger Str. 17 83404 Ainring Germany.
- GRASS Development Team. 2012. *Geographic Resources Analysis Support System (GRASS GIS) Software*. Open Source Geospatial Foundation, USA.
- Hernández, Luis Alberto Padrón. 2011. *Cómo Crear Documentos Científicos de Calidad con Herramientas de Software Libre*. 1 edn. Universidad de Las Palmas de Gran Canaria.
- Huang, Zhi, Turner, Brian J, Dury, Stephen J, Wallis, Ian R, & Foley, William J. 2004. Estimating foliage nitrogen concentration from HYMAP data using continuum removal analysis. *Remote Sensing of Environment*, **93**(1), 18–29.
- JARS. 1999. *Remote Sensing Note*. National Space Development Agency of Japan (NASDA).
- Jarvis, A., Reuter, H.I., Nelson, A., & Guevara, E. 2008. *Hole-filled seamless SRTM data V4*. International Centre for Tropical Agriculture (CIAT). <http://srtm.csi.cgiar.org>.
- Jiménez, Jorge A. 1994. El Manejo de los Manglares en el Pacífico de Centroamérica: Usos tradicionales y Potenciales. *Ecosistema de Manglar en América Tropical: Estructura, Función y Manejo. Serie Científica*, 275–290.
- Jiménez, Jorge A. 1985a. Laguncularia Racemosa (L.) Gaertn. f. Mangle blanco. *U.S. Department of Agriculture, Forest Service, Southern Forest Experiment Station*, 4 p.

Jiménez, Jorge A. 1985b. Rhizophora Mangle L. Mangle colorado. *U.S. Department of Agriculture, Forest Service, Southern Forest Experiment Station.*, 7 p.

Jiménez, Jorge A., & Lugo, Ariel E. 1985. Avicennia germinans (L.) L. Mangle prieto. *U.S. Department of Agriculture, Forest Service, Southern Forest Experiment Station*, 6 p.

Kokaly, Raymond F, & Clark, Roger N. 1999. Spectroscopic determination of leaf biochemistry using band-depth analysis of absorption features and stepwise multiple linear regression. *Remote Sensing of Environment*, **67**(3), 267–287.

LaboraTe. 2014. Investigación y sensibilización sobre la problemática de actividad acuícola insostenible y promoción de alternativas artesanales basadas en la economía social: puentes entre el Golfo de Fonseca (Centroamérica) y Galicia. *Consellería da Presidencia e Administración Pública*.

Lamport, L. 1994. LaTeX user's guide and reference manual (2^a edición). Addison Welsley. *Reading, Mass.*

Lara-Domínguez, Ana Laura, Yáñez-Arancibia, Alejandro, Yáñez-Arancibia, A, & Lara-Domínguez, AL. 1999. Productividad secundaria, utilización del hábitat y estructura trófica. *Ecosistemas de Manglar en América Tropical. Instituto de Ecología AC México, UICN/ORMA, Costa Rica, NOAA/NMFS Silver Spring, Maryland, USA*, 153–166.

Lee, Tsai-Ming, & Yeh, Hui-Chung. 2009. Applying remote sensing techniques to monitor shifting wetland vegetation: A case study of Danshui River estuary mangrove communities, Taiwan. *Ecological engineering*, **35**(4), 487–496.

Mas i Hernández, Jordi. 2005. *Software libre: técnicamente viable, económicamente sostenible y socialmente justo*. Infonomia.

Matellán Oliveira, Vicente, González Barahona, Jesús M., De Las Heras Quirós, Pedro, & Robles Martínez, Gregorio. 2004. *Sobre Software Libre (Ciencias Experimentales y Tecnología)*. Ciencias Experimentales y Tecnología URJC, vol. 2. Universidad Rey Juan Carlos.

Neteler, Markus, & Mitasova, Helena. 2002. *Open source GIS: a GRASS GIS approach*. Springer Science & Business Media.


- Olaya, Victor. 2010. *Sistemas de Informacion Geografica*. Proyecto Libre.
- R Core Team. 2013. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Ramsar. 2014 (September). *The List of Wetlands of International Importance*.
- Rouse, JW, Haas, RH, Schell, JA, Deering, DW, & Harlan, JC. 1974. Monitoring the vertical advancements and retrogradation of natural vegetation. *NASA/GSFC, Final Report, Greenbelt, MD, USA*, 1–137.
- Schowengerdt, Robert A. 2006. *Remote sensing: models and methods for image processing*. Academic press.
- Stevens, Antoine, & Ramirez-Lopez, Leonardo. 2014. *An introduction to the prospectr package*.
- Underwood, Emma, Ustin, Susan, & DiPietro, Deanne. 2003. Mapping nonnative plants using hyperspectral imagery. *Remote Sensing of Environment*, **86**(2), 150–161.
- USGS. 2015 (March). *Product Guide. Provisional Landsat 8 Surface Reflectance Product*. 1.2 edn. Department of the Interior U.S. Geological Survey.
- Yáñez-Arancibia, Alejandro, & Lara-Domínguez, Ana Laura. 1994. Los manglares de América Latina en la encrucijada. *Faro*, **1**, 3–7.

Anejo. Mapas

ÍNDICE DE VEGETACIÓN SAVI

Golfo de Fonseca. Escala 1:400000

Mapa 1/5



LEYENDA

SAVI

-0.195098
-0.172234
-0.149371
-0.126507
-0.103643
-0.080780
-0.057916
-0.035052
-0.012188
0.010675

Proyección: UTM

Huso: 16 Norte

Elípticoide: WGS84

Índice de Vegetación Ajustado a Suelo
Escala 1:400000



0 10 20 30 40 50 km

ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE MANGLE EN EL GOLFO
DE FONSECA. APPLICACIÓN A LA CLASIFICACIÓN DE IMÁGENES LANDSAT.



USC
UNIVERSIDADE
DE SANTIAGO
DE COMPOSTELA

Alumno: Rial Docampo, Marcos

Tutores: Corbelle Rico, Eduardo

Corrales Andino, Rafael Enrique

Universidad de Santiago de Compostela


Escuela Politécnica Superior de Lugo

Fecha: 1/7/2015

ÍNDICE DE VEGETACIÓN NDVI

Golfo de Fonseca. Escala 1:400000

Mapa 2/5



A horizontal scale bar representing distance in kilometers. It features major tick marks at intervals of 10 km, labeled 0, 10, 20, 30, 40, and 50 km. The scale bar is a solid black line with vertical end caps.

ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE MANGLE EN EL GOLFO DE FONSECA. APlicación A LA CLASIFICACIÓN DE IMÁGENES LANDSAT.

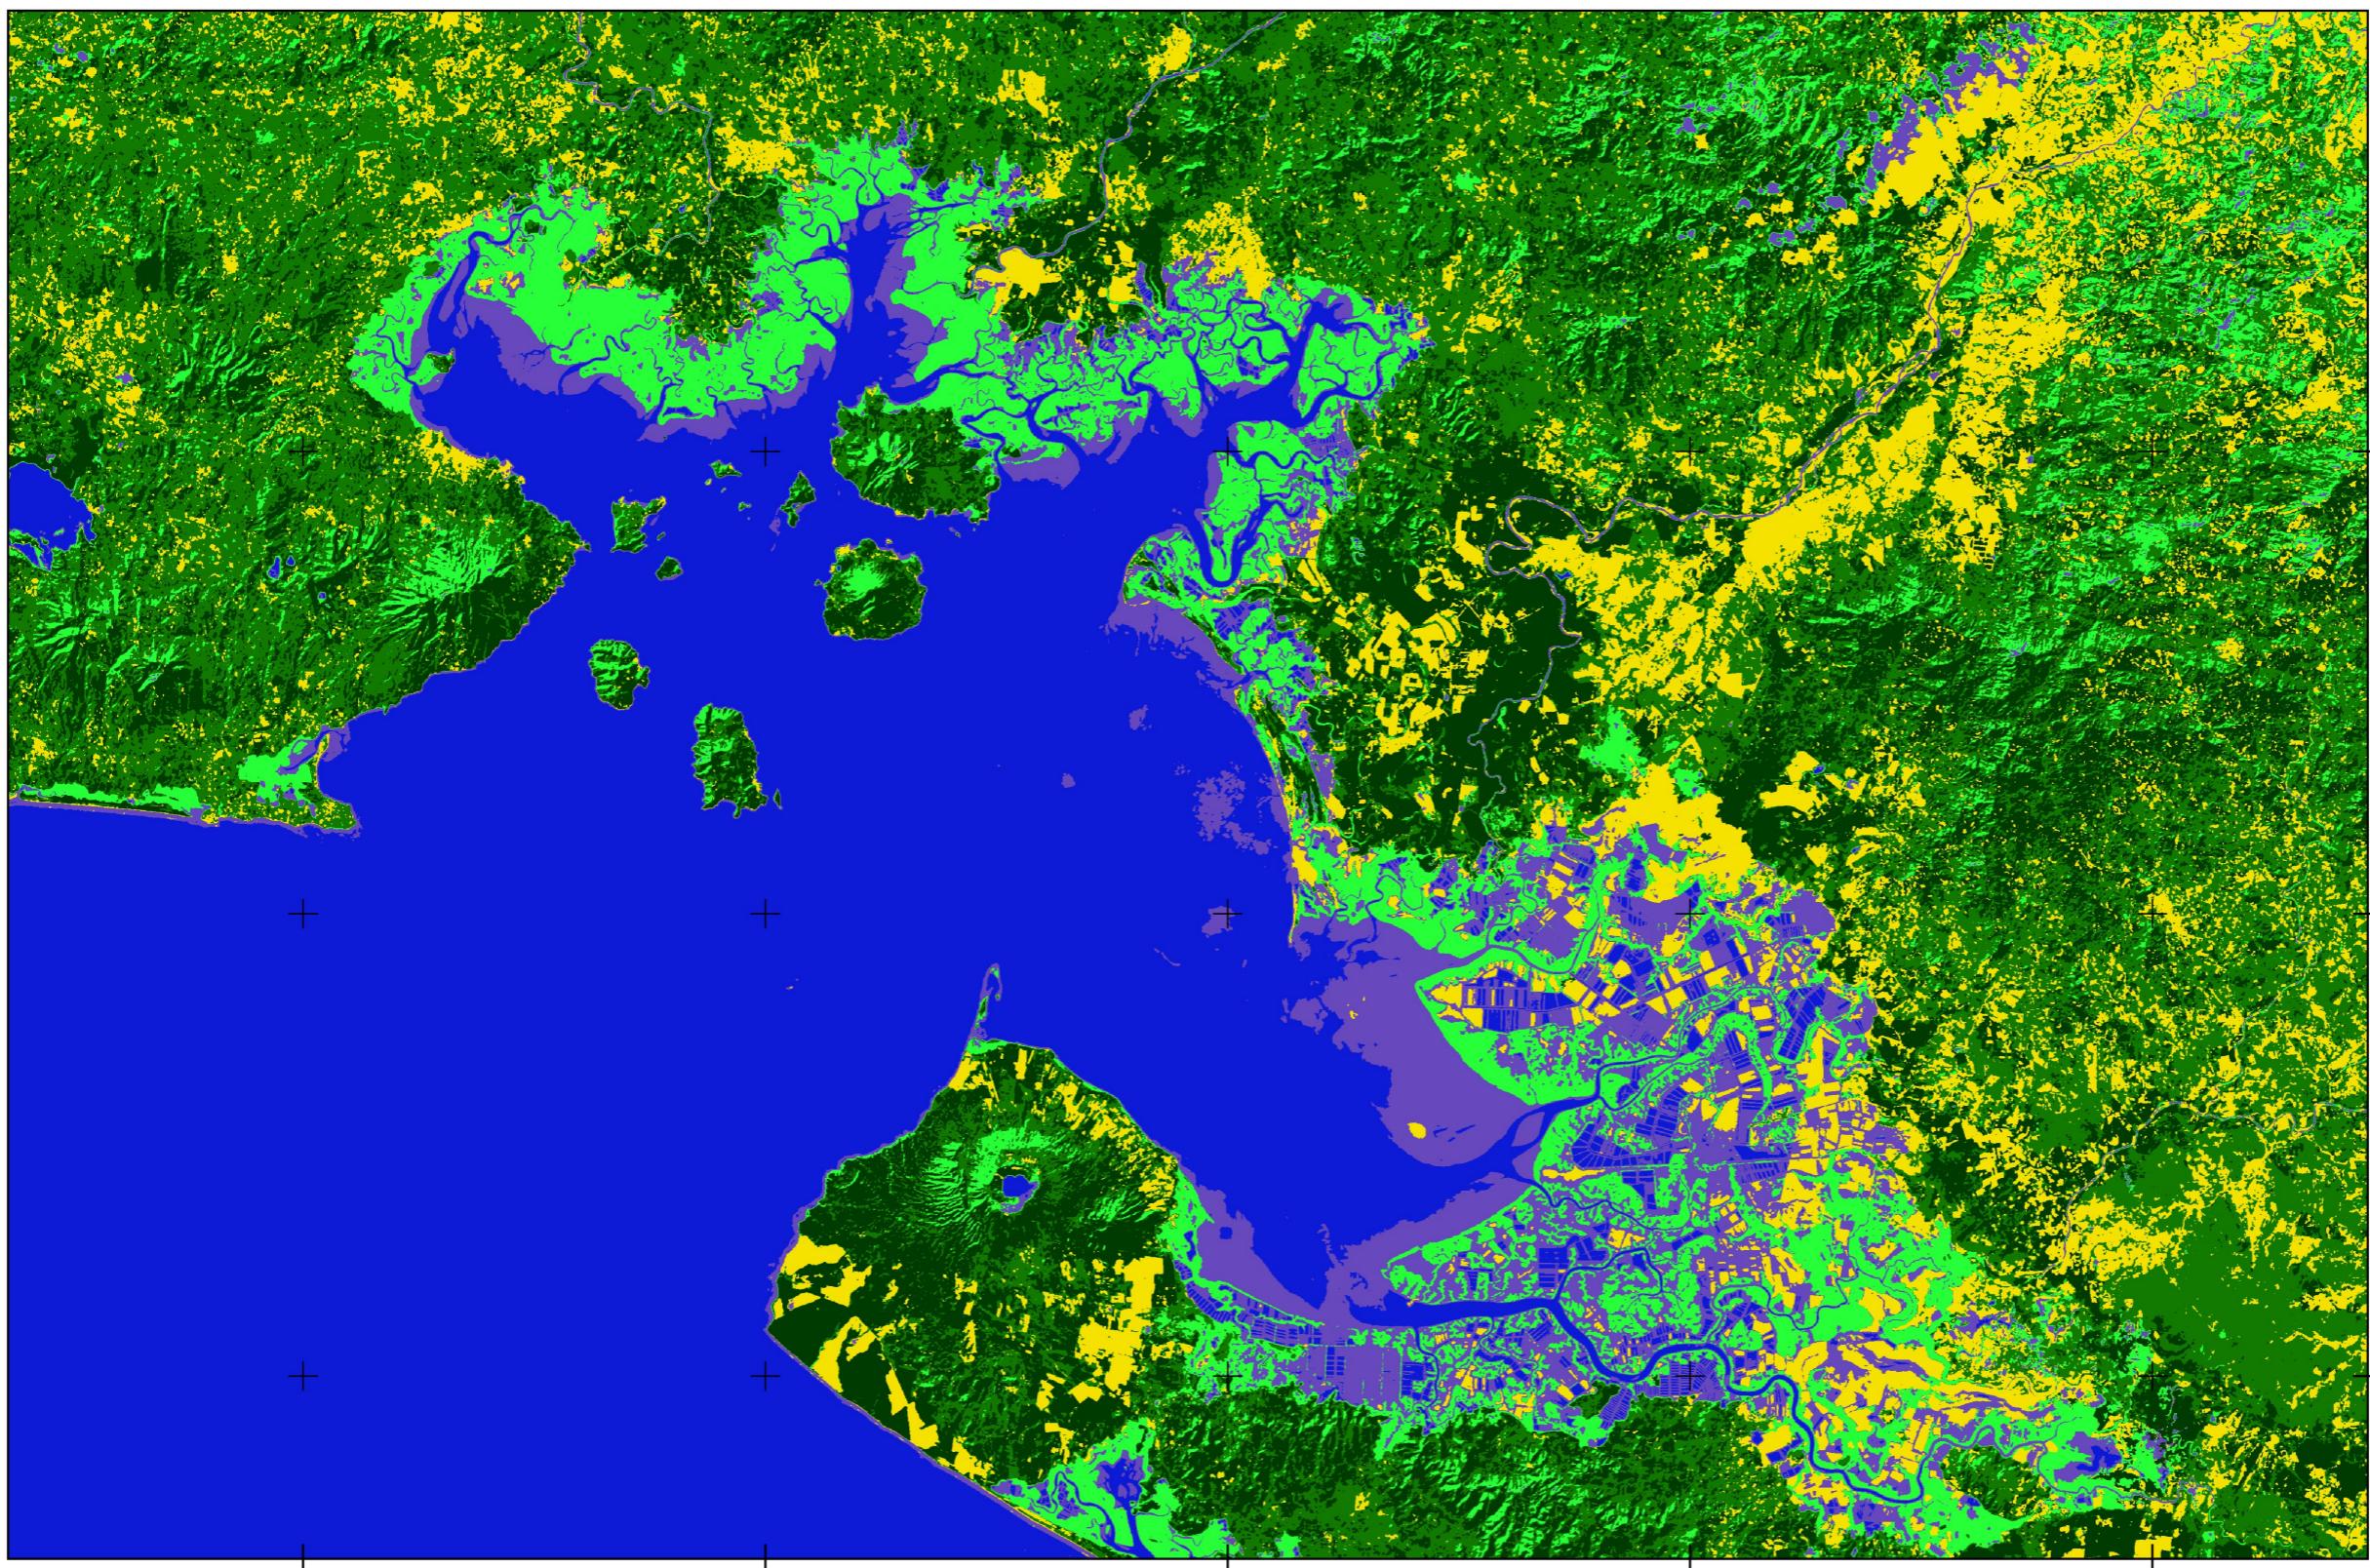


Alumno: Rial Docampo, Marcos
Tutores: Corbelle Rico, Eduardo
Corrales Andino, Rafael Enrique
Universidad de Santiago de Compostela
Escuela Politécnica Superior de Lugo
Fecha: 1/7/2015

CLASIFICACION NO SUPERVISADA MAXIMUM LIKELIHOOD

Golfo de Fonseca. Escala 1:400000

Mapa 3/5



LEYENDA

Clasificación

- Agua 1
- Agua 2
- Manglar
- Vegetación 1
- Vegetación 2
- Vegetación 3

Proyección: UTM

Huso: 16 Norte

Elípticoide: WGS84

Clasificación no supervisada MLC

Escala 1:400000



0 10 20 30 40 50 km

ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE MANGLE EN EL GOLFO
DE FONSECA. APPLICACIÓN A LA CLASIFICACIÓN DE IMÁGENES LANDSAT.

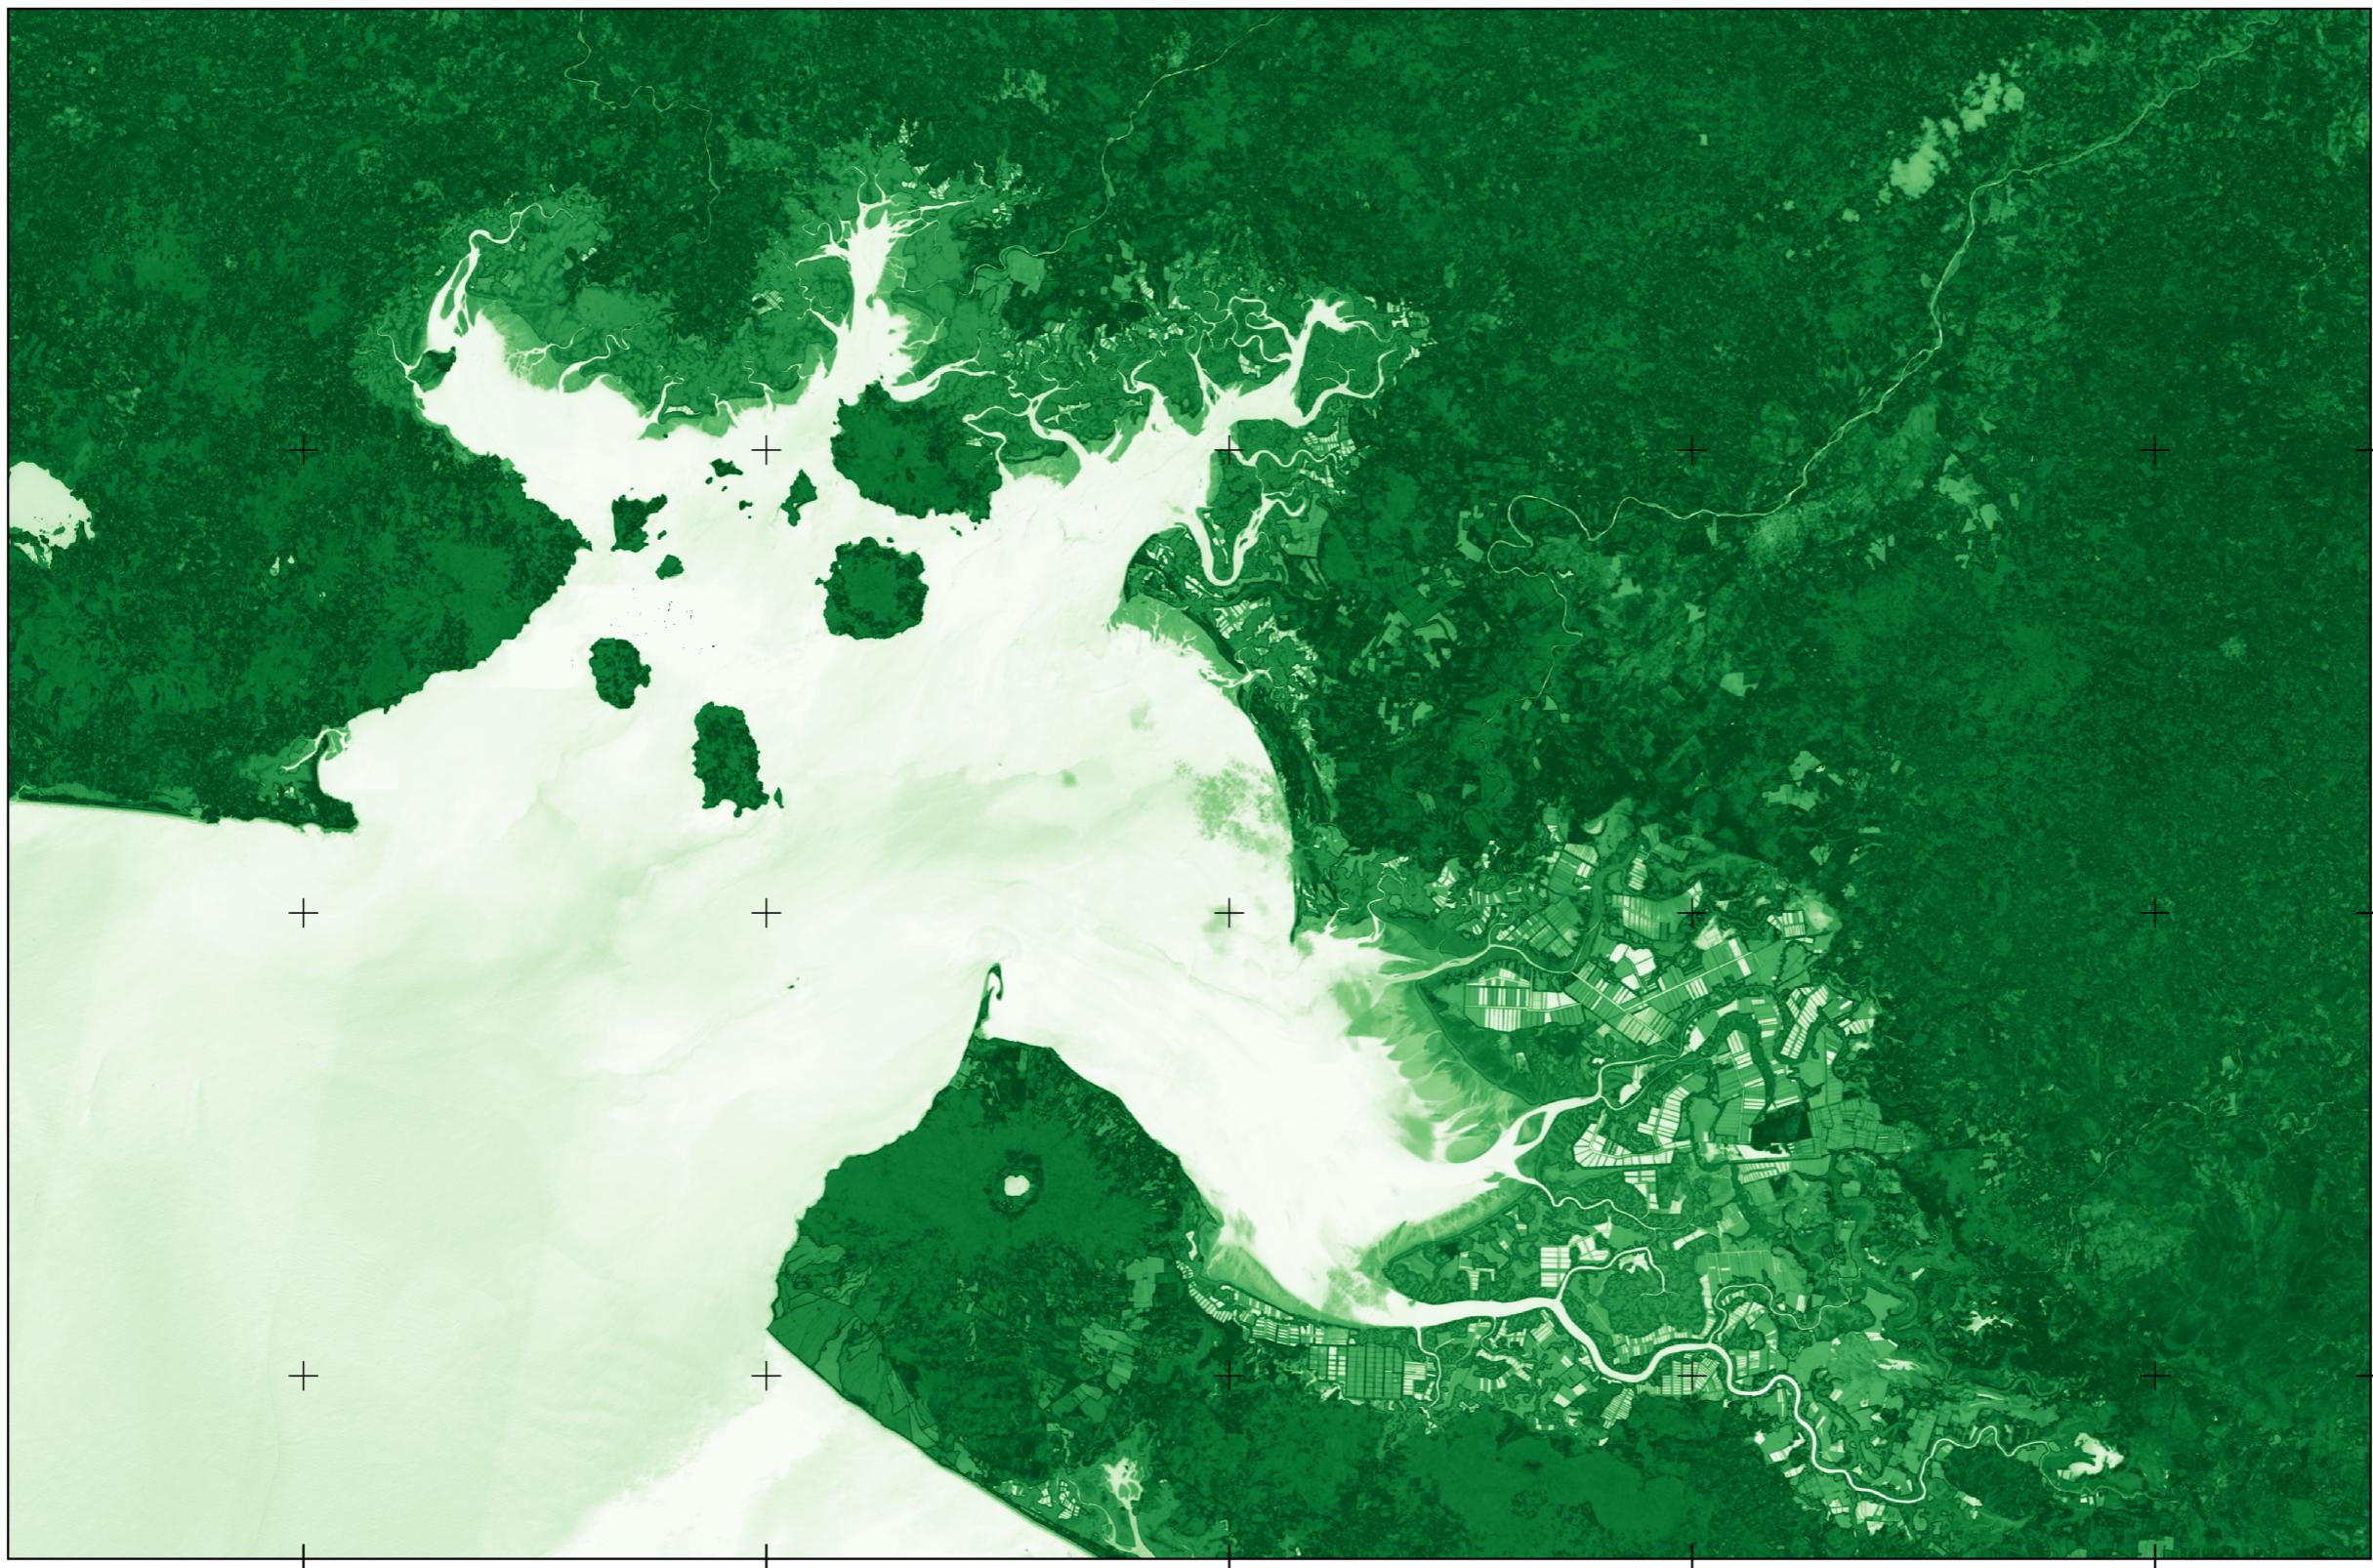


Alumno: Rial Docampo, Marcos
Tutores: Corbelle Rico, Eduardo
Corrales Andino, Rafael Enrique
Universidad de Santiago de Compostela
Escuela Politécnica Superior de Lugo
Fecha: 1/7/2015

CLASIFICACIÓN NO SUPERVISADA SPECTRAL ANGLE MAPPER

Golfo de Fonseca. Escala 1:400000

Mapa 4/5



LEYENDA

SAM

- 0.057865
- 0.212097
- 0.366330
- 0.520563
- 0.674795
- 0.829028
- 0.983261
- 1.125629
- 1.244270

Proyección: UTM
Huso: 16 Norte
Elípticoide: WGS84

Clasificación no supervisada SAM
Escala 1:400000



0 10 20 30 40 50 km

ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE MANGLE EN EL GOLFO
DE FONSECA. APPLICACIÓN A LA CLASIFICACIÓN DE IMÁGENES LANDSAT.



Alumno: Rial Docampo, Marcos
Tutores: Corbelle Rico, Eduardo

Corrales Andino, Rafael Enrique

Universidad de Santiago de Compostela


Escuela Politécnica Superior de Lugo

Fecha: 1/7/2015

CLASIFICACIÓN SUPERVISADA MAXIMUM LIKELIHOOD

Golfo de Fonseca. Escala 1:400000

Mapa 5/5



LEYENDA
Clasificación
Manglar
Agua 1
Vegetación 1
Agua 2
Vegetación 2

Proyección: UTM
Huso: 16 Norte
Elípticoide: WGS84
Índice de Vegetación de Diferencia
Normalizada



0 10 20 30 40 50 km

ANÁLISIS DE SEPARABILIDAD ESPECTRAL DE ESPECIES DE MANGLE EN EL GOLFO
DE FONSECA. APPLICACIÓN A LA CLASIFICACIÓN DE IMÁGENES LANDSAT.



Alumno: Rial Docampo, Marcos
Tutores: Corbelle Rico, Eduardo
Corrales Andino, Rafael Enrique
Universidad de Santiago de Compostela
Escuela Politécnica Superior de Lugo
Fecha: 1/7/2015